


Data Preprocessing

Contents

- Stufen der Daten-Vorverarbeitung
- Diskrepanzen / Fehler in Daten
- Beispiel: Palmer Penguins
- Aufgaben

Stufen der Daten-Vorverarbeitung



[Quelle](#)

Unser Fokus: Datensäuberung (Data Cleaning)

Diskrepanzen / Fehler in Daten

- Fehlende Werte (missing values)
- Verrauschte Daten (noisy data)
- Falsche Werte (false values)
- Inkonsistente Werte (inconsistent values)

Diskussion (3–5 Min.)

In der folgenden Tabelle sind ein paar typische Datenfehler versteckt. Welche finden Sie?

Pers.ID	Name	Geschlecht	Geburtstag	Alter	PLZ	Straße	Nr.
11	Schulze, Erwin	m	12.06.77	48	23966	Wagnerstr.	0
23	Erwin Schulze	w	00.00.00	null	23966	Wagnerstr.	4
11	Müller, Inge	w	16.12.86	29	06119	Mozartstr.	7
42	Lehmann, Anna	fem	30.2.78	37	66125	Bachstr.	31

▾ Einige typische Datenfehler

- **PersID=11** wurde 2 mal vergeben, sollte aber **eindeutig** sein
- Drei Werte **fehlen**: **Nr.** in Zeile 1; **Geburtstag** und **Alter** in Zeile 2
- **Widerspruch** zwischen **Geburtsdatum** und **Alter**
- Zeile 1 und 2 beschreiben **dieselbe Person**, allerdings mit unterschiedlichen Schreibweisen des Nachnamens
- Die Postleitzahl 06119 **ist ungültig**
- **Geburtsdatum** in Zeile 4 ist ein **ungültiger Wert**
- Der Wert **fem** für **Geschlecht** entspricht vermutlich **w**

Wie entstehen Diskrepanzen?

- schlecht designte Formulare, z.B. mit vielen optionalen Feldern
- Menschliche Fehler beim Erstellen der Daten
- absichtlich falsche oder fehlende Angaben (z.B. bei Fragebögen)
- Data decay (z.B. nicht mehr existierende Adressen)
- inkonsistente Verwendung von codes
- Fehler in Devices, welche Daten speichern, oder System-Fehler (z.B. Logging-Systeme)
- Inkonsistenzen bei der Datenintegration (z.B. Attribut hat verschiedene Namen in zwei fusionierten Datenbanken, oder falsche Format-Annahmen bei der Integration)
- Daten werden für einen anderen Zweck verwendet als ursprünglich angedacht
- ...

Wie können wir Diskrepanzen erkennen?

- Verwende **vorhandenes Wissen über die Daten** (Metadaten): welchen Typ sollte ein Attribut haben? Welche Werte können wir erwarten (z.B. Alter ≥ 0)? Gibt es Zusammenhänge zwischen den Attributen (z.B. Alter und Geburtsdatum)?
- **Deskriptive Zusammenfassungen** der Daten (sog. data summaries) zeigen Datentypen und Wertebereiche von Attributen und fassen statistische Eigenschaften der Daten zusammen, z.B. Mittelwert, Ausreißer.
- **Regeln prüfen**: Eindeutigkeit (Identifizier); Definition für fehlende Werte
- Achten auf **inkonsistente Repräsentationen**: z.B. "2004/12/25" vs. "25/12/2004"

Fehlende Werte

Fehler oder Information?

mögliches Vorgehen	Vor- und Nachteile
Attribut (Spalte) ignorieren	möglicherweise wichtige Information geht für alle Datensätze verloren
Datensatz (Zeile) ignorieren	falls viele Werte fehlen, reduziert es den Datensatz ggf. zu stark
Fehlende Werte manuell einfügen	zu aufwendig, wenn viele Werte fehlen
Fehlende Werte durch globale Konstante ersetzen	nur sinnvoll, falls das Fehlen als Information zu betrachten ist
Fehlenden Wert durch ein statistisches Lagemaß (z.B. Mittelwert) ersetzen	Manche Lagemaße nicht bei jedem Datentyp anwendbar; sinnvoll, wenn Werte nicht allzu sehr streuen; kann auch nach Gruppierung der Daten stattfinden
Fehlenden Wert durch wahrscheinlichsten Wert ersetzen	Algorithmen wie Entscheidungsbäume oder lineare Regression können mit Hilfe der anderen Variablen den wahrscheinlichsten Wert vorhersagen

Die letzten drei Ansätze verzerren die Daten. Am besten geeignet aber auch am

aufwendigsten ist der letzte Ansatz. Um diesen aber durchführen zu können, müssen die Prädiktor-Spalten selbst in einem guten Zustand sein....

Verrauschte Daten

Was ist Rauschen?

- Zufallsfehler oder starke statistische Varianz in den Werten einer Variable
- Entstehen häufig durch ungenaue Messungen oder Schätzungen
- Es gibt verschiedene Methoden, mit verrauschten Daten umzugehen - von Entfernen über Glätten bis Korrigieren

Glättung durch Klasseneinteilung (Binning)

- Sog. Binning-Methoden glätten Werte unter Verwendung der "näheren Umgebung" – > lokale Glättung
- Je größer die Streuung innerhalb der Bins, desto größer der Glättungseffekt
- Andere Bins, z.B. Bins gleicher Breite können ebenfalls verwendet werden

Beispiel

$$x = [1, 4, 7, 15, 21, 21, 26, 28, 36]$$

Binning

A) Gleiche Breite (z. B. Breite = 10):

- Bin 1: 1, 4, 7
- Bin 2: 15
- Bin 3: 21, 21, 26, 28
- Bin 4: 36

B) Gleiche Anzahl (z.B. je 3 Werte)

- Bin 1: 1, 4, 7
- Bin 2: 15, 21, 21

- Bin 3: 26, 28, 36

2) Glättung (binweise ersetzen)

- **Mean smoothing:** ersetzen durch **Mittelwert** des Bins
- **Bin boundaries:** ersetzen durch **nächste Bin-Kante**

Ergebnisse (in Originalreihenfolge):

Für gleiche Breite

- Mean: [4, 4, 4, 15, 24, 24, 24, 24, 36]
- Boundaries: [1, 1, 7, 15, 21, 21, 28, 28, 36]

Für gleiche Anzahl

- Mean: [4, 4, 4, 19, 19, 19, 30, 30, 30]
- Boundaries: [1, 1, 7, 15, 21, 21, 26, 26, 36]

Ausreisser (outlier) erkennen

Behandlung von Outliern funktioniert dann analog zu fehlenden Werten.

- Ganz allgemein gesprochen ist ein Ausreißer ein Datenpunkt, der sich *signifikant* von anderen Datenpunkten unterscheidet.
- Dies hängt allerdings von der zugrundeliegenden statistischen Verteilung ab.
- Wir beschränken uns auf die unabhängige Betrachtung einzelner Variablen.


IQR-Regel

Werte oberhalb von $Q3 + 1.5 * IQR$ und unterhalb von $Q1 - 1.5 * IQR$ sind gute Outlier-Kandidaten

Wo kommt die IQR-Regel her?

- Box-Whisker-Plots wurden in 1977 von John Tukey eingeführt; er definierte auch diesen Grenzwert
- hat gut funktioniert und wird weiter benutzt

- Sie basiert auf der **Anzahl** an Datenpunkten in einem bestimmten Bereich bei Variablen, die möglichst normalverteilt sind ("glockenartig") - max. ~1% der Daten können als Outlier gelten.




M. W. Toews, CC BY 2.5, [Quelle](#)

- Ca. 68.26% der Datenpunkte liegen innerhalb einer Standardabweichung ($< 1 \cdot \sigma$) um den Mittelwert (μ , hier 0), im Bild die dunkelblue Region im Zentrum.
- Ca. 95.44% der Datenpunkte liegen innerhalb von zwei Standardabweichungen ($< 2 \cdot \sigma$) um den Mittelwert (μ , hier 0)
- ...
- Das erste und dritte Quartil, Q1 und Q3, liegen jeweils bei $-0.675 \cdot \sigma$ und $+0.675 \cdot \sigma$ vom Mittelwert. Multipliziert mit 1.5 erhalten wir die Entfernung $2.7 \cdot \sigma$. Bei der Gausschen Normalverteilung betrachtet man $3 \cdot \sigma$ als die Outlier-Grenze (Grenze zu sehr unwahrscheinlichen Werten).

Verbundbildung (Clustering)

- Bilde Cluster (Gruppen) von "ähnlichen" Werten & betrachte Werte außerhalb der Cluster als Ausreißer
- Benötigt ein Konzept von "Ähnlichkeit" -> darüber lernen wir mehr im Laufe des Semestern, wenn wir uns mit unüberwachtem Lernen beschäftigen



Inkonsistente und falsche Daten

Zahlreiche Ausprägungen vorhanden, deshalb teils schwer zu finden

Beispiele:

- **Datentyp:** eine Postleitzahl in Deutschland besteht aus Ziffern, der Datentyp sollte ein Integer sein oder sich entsprechend konvertieren lassen
- **Wertebereich:** Das Alter eines Menschen ist eine Zahl zwischen 0 und 200, ein Mensch kann also nicht -30 oder 1450 Jahre alt sein
- **Synonyme:** verschiedene Notationen für den gleichen Wert, z.B. 'f' und 'w' für Frau
- **Plausibilität:** ein sonst umsatzschwacher Kunde hat plötzlich einen enormen Jahresumsatz
- **Widersprüche:** das Alter einer Kundin und ihr Geburtsort müssen zusammenpassen

Man kann versuchen, fehlerhafte oder inkonsistente Werte durch zusätzliche Informationen zu korrigieren. Ansonsten gibt es (nur noch) die Möglichkeit, die entsprechenden Attribute oder Datensätze zu ignorieren.

Beispiel: Palmer Penguins

Hide code cell source

```
import pandas as pd
from os.path import join
file_path = join('data', 'penguins_lter.csv')
penguins = pd.read_csv(file_path)
```

```
penguins.sample(3)
```

	studyName	Sample Number	Species	Region	Island	Stage	Individual ID	Cor
146	PAL0910	147	Adelie Penguin (Pygoscelis adeliae)	Anvers	Dream	Adult, 1 Egg Stage	N83A1	
316	PAL0910	97	Gentoo penguin (Pygoscelis papua)	Anvers	Biscoe	Adult, 1 Egg Stage	N20A1	
233	PAL0708	14	Gentoo penguin (Pygoscelis papua)	Anvers	Biscoe	Adult, 1 Egg Stage	N37A2	

Was würden Sie überprüfen?

```
# Datentypen
penguins.dtypes
```

```

studyName          object
Sample Number      int64
Species            object
Region             object
Island             object
Stage             object
Individual ID      object
Clutch Completion  object
Date Egg           object
Culmen Length (mm) float64
Culmen Depth (mm)  float64
Flipper Length (mm) float64
Body Mass (g)      float64
Sex                object
Delta 15 N (o/oo)  float64
Delta 13 C (o/oo)  float64
Comments           object
dtype: object

```

```
penguins.describe()
```

	Sample Number	Culmen Length (mm)	Culmen Depth (mm)	Flipper Length (mm)	Body Mass (g)	Del
count	344.000000	342.000000	342.000000	342.000000	342.000000	330.0
mean	63.151163	43.921930	17.151170	200.915205	4201.754386	8.1
std	40.430199	5.459584	1.974793	14.061714	801.954536	0.0
min	1.000000	32.100000	13.100000	172.000000	2700.000000	7.0
25%	29.000000	39.225000	15.600000	190.000000	3550.000000	8.1
50%	58.000000	44.450000	17.300000	197.000000	4050.000000	8.0
75%	95.250000	48.500000	18.700000	213.000000	4750.000000	9.0
max	152.000000	59.600000	21.500000	231.000000	6300.000000	10.0

Information eigentlich nur für metrische Merkmale sinnvoll

```

# Anzahl eindeutiger Werte pro Spalte
for col in penguins.columns:
    print(col, penguins[col].nunique())

```

```
studyName 3
Sample Number 152
Species 3
Region 1
Island 3
Stage 1
Individual ID 190
Clutch Completion 2
Date Egg 50
Culmen Length (mm) 164
Culmen Depth (mm) 80
Flipper Length (mm) 55
Body Mass (g) 94
Sex 3
Delta 15 N (o/oo) 330
Delta 13 C (o/oo) 331
Comments 7
```

- **Island** und **Species** haben jeweils 3 eindeutige Werte - ergibt Sinn laut Dokumentation
- Die **Delta**-Attribute haben mehr als 300 eindeutige Werte, d.h. nahezu jeder Wert kommt nur einmal vor
- Attribut **Sex** hat 3 eindeutige Werte, laut Beschreibung sollten es 2 sein
- **Individual ID** klingt in Dokumentation wie eine eindeutige Kennung aber das scheint nicht zu stimmen
- ...

Aufgaben

Aufgabe 1

Nutzen Sie [das Notebook](#), um sich mit der Python-Bibliothek pandas für Verarbeitung tabellarischer Daten vertraut zu machen.

Aufgabe 2

Nutzen Sie die pandas Bibliothek, um sich mit dem Palmer Penguins Datensatz vertraut zu machen. Führen Sie erste Schritte der Datenbeschreibung, -visualisierung und Exploration durch. Überprüfen Sie den Datensatz auf Fehler und fehlende Werte.