

Einführung in Maschinelles Lernen

Contents

- Wofür Machine Learning (ML)
- Wichtigste Konzepte und Begriffe des ML
- Übungen

Lernziele

- Verstehen, wofür Maschinelles Lernen (= Machine Learning = ML) eingesetzt wird
- Wichtigste Konzepte und Begriffe des ML kennenlernen
- Ein ML Problem mathematisch formulieren


Wofür Machine Learning (ML)

Seit einigen Jahren ist Machine Learning (ML) zu einem Standardwerkzeug für fast alle Aufgaben geworden, bei denen **Informationen aus Daten extrahiert** werden müssen.

- Daten: Rohinformationen
- Information: Daten mit Kontext, verarbeitet, Wert.

Machine Learning kommt v.a. zum Einsatz bei Aufgaben, die wir mit einer **expliziten Abfolge von Regeln** nicht gut lösen können.

Beispiel: Objekterkennung in Bildern



Objekterkennung auf Bildern (Bereich und Kategorie des Objekts).

- Wir wissen nicht, wie wir ein solches Programm schreiben sollen, **da wir nicht wissen, wie unser Gehirn Objekte erkennt**
- Selbst wenn wir einen Regelbasierten Ansatz hätten, wäre er vermutlich extrem komplex
- Ähnliches gilt für Autonomes Fahren, Spracherkennung

Ein Programm zu schreiben, das die **Wahrscheinlichkeit für Kreditkartenbetrug** berechnet, ist ebenfalls sehr schwer:


- Es gibt vermutlich keine Regeln, die gleichzeitig einfach und zuverlässig sind. Wir müssten eine große Menge schwacher Regeln kombinieren

- Betrug ist ein "bewegtes Ziel": Betrüger*innen ändern ihre Methoden, das Programm müsste also **kontinuierlich angepasst** werden

Manche Aufgaben gehen über menschliche Fähigkeiten hinaus, z.B. wenn das Ziel die **Analyse großer, komplexer Daten** wie:

- Daten in der Astronomie
- Medizinisches Wissen aus medizinischen Archiven extrahieren
- Wetter-Vorhersage
- Analyse von Genomdaten
- Web-Suchmaschinen

Beispiel: Vorhersage des Effekts einzelner Aminosäure-Mutationen in Proteinen



Vorhersage des Effekts von Missense-Varianten mit Hilfe des AlphaMissense Modells. [Quelle: Jun Cheng et al. \(2023\)](#)

ML Verfahren sind also besonders dann sinnvoll, wenn:


- Probleme nicht mit Hilfe von wenigen, einfachen und zuverlässigen Regeln gelöst

werden können

- Wir die Lösung des Problems gar nicht genau kennen (Bsp.: Bilderkennung)
- Zu erwarten ist, dass sich die Daten häufig ändern werden (Bsp.: Kreditkartenbetrug)
- Implementierung eines klassischen Programms sehr zeitintensiv ist
- Der Mensch das Problem selbst gar nicht lösen kann
- "Genügend gute" Daten vorhanden sind, aus denen "gelernt" werden kann!

Beispiel: wake word

Sprach-basierte Assistenten wie Alexa oder Siri werden über ein sog. *wake word* aktiviert (z.B. "Alexa" oder "Hey Siri").



Diskussion (3–5 Min.)

Wie könnte man ein Programm schreiben, welches das 'wake word' erkennt (Programmiersprache egal)?

▾ (Un-)mögliche Lösung

Dies ist ein sehr schweres Problem. Es ist unmöglich Regeln zu formulieren, um das Audio-Signal zuverlässig und robust zu verarbeiten und zu klassifizieren.

Alternative:

- Wir können **viele** Audio-Dateien und zugehörige Labels (yes, no) sammeln.
- Wir definieren eine **geeignete Metrik**, um die Performanz von Programmen zu **messen** (z.B. Anteil der korrekt erkannten Wörter)
- Wir definieren ein **flexibles Programm**, welches von verschiedenen **Parametern** abhängt, und verwenden die gesammelten Daten, um die **optimalen Parameter** zu finden, d.h. diejenigen Parameter, welche im Sinne der gewählten Metrik die

besten Ergebnisse erzielen.

- Wir definieren für diese **Lernaufgabe** ein geeignetes Verfahren.


Wichtigste Konzepte und Begriffe des ML

Was bedeutet in diesem Zusammenhang *Lernen*?


- Umwandlung von **Erfahrung** in **Kenntnisse oder Wissen**.
- Der **Input** eines Lernalgorithmus sind **(Trainings-)Daten**, die Erfahrung darstellen.
- Der **Output** ist Wissen/Expertise, normalerweise in Form eines **Programms**, das eine bestimmte (komplexe) Aufgabe erfüllen kann
- Wenn wir die Parameter des Programms festgelegt haben, sprechen wir von einem **Modell**. Die Menge aller solchen Programme, die durch eine Festlegung der Parameter entstehen, nennen wir eine **Modell-Familie** oder **Familie von Modellen**. (In der Mathematik spricht man allgemein von Familien von Funktionen, z.B. wenn diese sich als geschlossene Formel in Abhängigkeit eines Parameters formulieren lassen, z.B. $f_a(x) = a \cdot \sin(x)$).
- Beispiel: Die Menge aller **linearen Funktionen**

$$f(x_1, \dots, x_n) = a_0 + a_1x_1 + \dots + a_nx_n,$$

wobei $x_1, \dots, x_n$ **Attribute unserer Daten** sind und $a_0, \dots, a_n$ die **zu lernenden Parameter**.




- Das **"Meta-Programm"**, welches wir einsetzen, um die optimalen Parameter zu finden, heißt **Lern-Algorithmus** oder **Lernverfahren (learning algorithm)**.
- Die Audio-Dateien sind der sog. **Input (Eingabe)** (für den Lern-Algorithmus und die Modelle), die Kategorien "yes" und "no" sind der sog. **Output (Ausgabe)**.
- Das Finden der "besten" Parameter in einer Modell-Familie mit Hilfe der gesammelten Daten ist das sog. **Training** oder **Modell-Training**.



Die Wahl der **Modell-Familie hängt von der Art der Aufgabe ab**. Intuitiv sollte eine Modell-Familie, die für das Lernen des Wake Words "Alexa" gut geeignet ist, auch dann noch geeignet sein, wenn wir "Hey Siri" als wake word lernen wollen. Für das Problem der

Objekterkennung in Bildern wird diese Modell-Familie voraussichtlich nicht gut geeignet sein.

Das **Training** läuft typischerweise folgendermaßen ab:



Zusammenfassung: Was wird benötigt?

1. **Daten** für das **Training** und die **Evaluation** des Modells
2. **Modell-Familie**
3. **Zielfunktion**, welche misst, wie gut ein Modell ist (engl.: **objective function**, auch **loss function**)
4. **Algorithmus**, der die Parameter des Modells im Sinne der Zielfunktion anpasst

Daten

- Wir sammeln Daten, die (statistisch) denjenigen **ähneln**, auf die das trainierte Modell später angewendet werden soll
- Damit ein Lern-Algorithmus Daten verarbeiten kann, ist üblicherweise eine "geeignete" **numerische Repräsentation der Daten** notwendig (es gibt bessere und schlechtere; dazu mehr im Laufe des Semesters)
- Jeder **Datenpunkt** (Daten-Sample, Daten-Beispiel) besteht aus sog. **Features**,

welche relevante Informationen der Datenpunkte repräsentieren und auf welchen die Vorhersagen des Modells basieren

- Im Falle des **überwachten Lernens (supervised learning, SL)** ist das Ziel, den Wert der sog. **Zielvariable** vorherzusagen, die nicht Teil des Modell-Inputs ist. Wird die Zielvariable als stetige numerische Variable **modelliert** (z.B. Temperatur, Dauer), sprechen wir von **Regression**; handelt es sich um eine Variable mit endlich vielen Werten (z.B. ja/nein, Schuh-Marken), sprechen wir von **Klassifikation**. Die verschiedenen Werte, welche die Zielvariable annehmen kann, heißen **Klassen** oder **Kategorien**.

Diskussion (3–5 Min.)

Diskutieren Sie folgende Aspekte anhand eines Anwendungsfalls Ihrer Wahl (siehe Auswahl unten).

- Handelt es sich um eine Regressions- oder Klassifikationsaufgabe? Im Falle einer Klassifikation: wieviele mögliche Werte hat die Zielvariable (Anzahl Klassen)?
- Wie würden Sie Daten für das Training sammeln?
- Wie würden Sie die Input-Daten numerisch repräsentieren?

Sie können aus den folgenden Anwendungsfällen wählen:

1. Vorhersage, ob auf einem Foto, aufgenommen z.B. mit einer iPhone 7 Kamera, ein Gesicht zu sehen ist
2. Vorhersage, ob in einem Film-Review eine positive oder negative Stimmung vermittelt wird
3. Vorhersage, wann ein*e Patient*in nach der Entlassung aus dem Krankenhaus wieder ins Krankenhaus kommen wird, basierend auf den Daten aus der Gesundheitsakte
4. Vorhersage des nächsten Wortes in HipHop-Lyrics

▸ Anwendungsfall 1

- Binäre Klassifikationsaufgabe. (Aber es ist möglich, die Aufgabe auch als Regression zu modellieren, indem nur die Wahrscheinlichkeit für Label: "ja" vorhergesagt wird)
- Selbst Fotos aufnehmen; Crowd-Collection; Internet-Quelle suchen (Richtlinien für Nutzung der Daten beachten), ...

- Wir nehmen hier eine feste Auflösung der Fotos an, z.B. 200 x 200 Pixel, da ein Kamera-Typ, und dass es sich um Fotos in Farbe handelt. Dann würden wir jedes Pixel als RGB Code repräsentieren; somit würde jedes Datenbeispiel $200 \cdot 200 \cdot 3 = 120,000$ Features haben.

▼ Anwendungsfall 3

- Regressionsaufgabe (Zielvariable ist Anzahl an Tagen, nach oben offen)
- Angenommen, wir arbeiten für das Krankenhaus selbst und haben Zugang zu den Akten der Patient*innen, die dort aufgenommen wurden, würden wir diese verwenden. Aus diesen lassen sich nicht nur Angaben über den Gesundheitszustand der Person entnehmen sondern auch, wann sie im Krankenhaus aufgenommen wurden (Werte für die Zielvariable)
- Attribute wie Laborwerte, bestehende Erkrankungen sowie sozio-demographische Angaben beinhalten sicherlich relevante Informationen. Ein Teil davon ist bereits numerisch; Kategorische Attribute müssen über Verfahren wie das sog. One-Hot-Encoding umgewandelt werden.

▼ Anwendungsfall 4

- Klassifikationsaufgabe; jedes Wort aus dem Vokabular ist eine Klasse; entsprechend hängt die Anzahl von Klassen von der Größe des Vokabulars ab (sehr groß, außer wir reduzieren das geschickt; dazu später im Semester mehr)
- Lyrics aus dem Internet herunterladen
- Für numerische Repräsentation gibt es viele Möglichkeiten. Man kann sog. One-Hot-Encoding durchführen (Angenommen das Vokabular ist alphabetisch sortiert und hat die Größe N . Dann wird jedes Wort repräsentiert als ein Vektor der Länge N bestehend aus einer 1 an der Index-Position des Wortes im Vokabular und sonst aus Nullen). Man kann auch semantische Repräsentationen lernen; dazu später im Semester mehr.

- In diesen Fällen haben die Repräsentationen der Daten eine feste Länge. Dies ist die **Dimension** der Daten bzw. des mathematischen Vektorraums der Input-Daten.
- Nicht alle Daten lassen sich immer gut mit Vektoren fixer Länge repräsentieren. Z.B. stammen nicht alle Bilder aus der gleichen Quelle (können nicht immer die gleiche

Kamera annehmen). Genauso sind Texte oder Video-Sequenzen unterschiedlich lang.

- Reduzieren geht zwar immer, führt jedoch auch zu **Informationsverlust**.
- Ein großer Vorteil einiger Deep Learning Architekturen ist ihre Fähigkeit, Daten-Repräsentationen unterschiedlicher Länge zu handhaben.

Datenquantität und -qualität

- Deep Learning (DL) Modelle benötigen mehr Daten als klassische ML Verfahren. Mehr Daten war der Haupt-Driver für den Erfolg von DL Modellen
- Datenqualität ebenfalls relevant: Fehler in Daten minimal halten, statistisch repräsentativ, etc. Dies hat nicht nur Einfluss auf Performance der Vorhersage (die kann ja gut sein auf Testdaten), sondern auch negative Konsequenzen hinsichtlich potenzieller Diskriminierung und Benachteiligung (z.B. Vorhersage von Hautkrebs aber Trainingsdaten hatten kaum Samples von PoCs). Disclaimer: Diskriminierung durch ML Modelle lässt sich nicht (nur) technisch lösen; es gibt weitaus mehr Probleme als unausgewogene Trainingsdaten.

Modell-Familie

- Für viele Vorhersagen auf tabellarischen Daten liefern klassische ML Verfahren oftmals sehr gute Ergebnisse, die von DL Modellen nicht übertroffen werden.
- **DL Modell-Familien werden v.a. bei komplexen Problemen angewendet, wie z.B. Objektklassifikation in Bildern, Vorhersage des nächsten oder des fehlenden Wortes in Texten (sog. Language Models) oder Generierung von Bild- oder Videomaterial.**
- Sie werden insbesondere auf Daten angewendet, **für die eine sinnvolle Repräsentation erst gelernt werden muss** (Die Pixel-Darstellung bei Bildern oder die One-Hot-Vektoren von Text sind an sich sehr Informationsarm).
- DL Modelle bestehen aus mehreren (teils vielen) Transformationen der Daten, die hintereinander in einer Kette ausgeführt werden. Dabei wechseln sich lineare und nicht-lineare Transformationen ab. Mathematisch kann auf diese Weise eine (beliebig) hohe Anpassung an die Muster in den Daten, die entdeckt werden sollen, erreicht werden.

Zielfunktion (objective function)

- Unter **Lernen** verstehen wir **Lernen aus Erfahrung**, und die **Erfahrung ist repräsentiert mit Hilfe von Trainingsdaten**.
- Das Ziel ist es, mit der Zeit besser in der zu lösenden Aufgabe zu werden.
- Aber was bedeutet **besser** (oder, analog, **schlechter**)?
- Diese Entscheidung muss als mathematische Funktion formalisiert werden (und es kann mehrere sinnvolle Optionen geben): sog. **Zielfunktion**, auf engl. **objective function**
- Typischerweise formulieren wir die Funktion so, dass sie den **Fehler** darstellt, den wir **minimieren** wollen; in dem Fall sprechen wir von der **loss function** (deutsch: **Verlustfunktion**, verwende ich quasi nie). Kann aber immer qualitativ gleichbleibend als Maximierungsaufgabe umformuliert werden.

Diskussion (3–5 Min.)


Welche Funktion / welchen Fehler könnte man im Falle einer Regression / Klassifikation minimieren?

▾ Regression

Für Regression wird typischerweise der **Mean Squared Error** gewählt:

$$\frac{1}{n} \cdot (y_1 - \hat{y}_1)^2 + \dots + (y_n - \hat{y}_n)^2,$$

wobei y_i die Werte der Zielvariable der Trainingsdatenpunkte ist und $\hat{y}_i$ die Werte der vorhergesagten Zielvariable.



▾ Klassifikation

Für Klassifikation würde sich inhaltlich die sog. **Fehlerrate** oder **Ungenauigkeit** (engl. **error rate, inaccuracy**) anbieten. Diese entspricht dem **Anteil falsch klassifizierter Datenpunkte**.

Diese lässt sich, im Gegensatz zum MSE, nicht gut optimieren (dies hat mathematische Gründe wie z.B. Nicht-Differenzierbarkeit); deshalb wird eine Ersatzfunktion verwendet, die sog. **Cross Entropy Loss**; über sie lernen wir im Semester mehr.

- Zur Erinnerung (Bild oben): Wir starten mit einem **initialen Modell**, das im Sinne unserer Loss-Funktion, ausgewertet auf den Trainingsdaten, sicher schlecht performt
- Wir wollen die Parameter im Laufe des Trainings so anpassen, dass der **Verlust** (die **Loss**) auf den Trainingsdaten **geringer** wird
- Für die Loss Function sind die Parameter des Modells die Parameter/die Unbekannten, und die Werte aus den Trainingsdaten sind Konstanten
- Nach einer Weile werden wir ein Modell finden, das auf den Trainingsdaten sehr gut performt (DL Modelle bekommen das in der Regel hin, sofern wir die richtige Modell-Familie ("Architektur") gewählt haben)

- Wir wollen aber ein Modell, das auf neuen, **ungesehenen Daten sehr gut performt**. Deshalb legen wir einen Teil der Daten beiseite, sog. **Test-Daten**, und werten das Modell auch auf diesen Daten aus. Das ist interessantere/wichtigere Evaluation.
- Wenn ein Modell auf den Trainingsdaten sehr gut performt aber nicht auf den Testdaten, sprechen wir vom **Overfitting**

Algorithmus zur Lösung der Optimierungsaufgabe

- Mit den bisherigen Schritten haben wir die Aufgabe mathematisch formalisiert und haben Daten gesammelt, mit welchen wir die Optimierungsaufgabe lösen können. Es fehlt der Algorithmus, welcher die optimalen Parameter in der Modell-Familie (also das optimale Modell) für unsere Daten identifiziert.
- Bei DL Modell-Familien werden Algorithmen basierend auf dem sog. **Gradientenabstieg** (engl. **gradient descent**) verwendet. Grob gesagt, prüft dieses Verfahren in jedem Schritt, in welche Richtung die Parameter verändert werden müssen, damit die Loss auf den Trainingsdaten so viel wie möglich reduziert wird.
- Hierfür müssen wir sog. **Richtungsableitungen** berechnen.
- Im Rahmen dieser LV werden wir auf dieses Thema kaum eingehen können (Wahlpflicht Deep Learning).

Übungen

Aufgabe 1 - Begriffe

Welche der folgenden Aussagen ist korrekt?

1. Trainingsdaten werden verwendet, um ein maschinelles Lernmodell zu trainieren.
2. Beim maschinellen Lernen ist ein Modell eine spezifische Instanz einer Modell-Familie.
3. Ein Lernalgorithmus wird verwendet, um das optimale Modell einer Modell-Familie zu identifizieren.
4. Überwachtes Lernen ist eine Form des maschinellen Lernens, bei der das Modell aus gelabelten Daten lernt.
5. Eine Überanpassung/Overfitting liegt vor, wenn ein Modell für maschinelles Lernen zu einfach ist und die Komplexität der Daten nicht erfassen kann.
6. Ein Feature ist eine messbare Eigenschaft oder Charakteristik der Daten.

7. Der Test-Datensatz wird zum Trainieren eines maschinellen Lernmodells verwendet.
8. Der Gradientenabstieg ist ein häufig verwendetes Optimierungsverfahren beim Deep Learning.

Aufgabe 2 - Operationalisierung eines ML Problems


Nennen Sie einen Anwendungsfall für Maschinelles Lernen, der Ihnen im Rahmen Ihres Studiums / Ihrer Arbeit / oder im täglichen Leben bisher begegnet ist.

Überlegen Sie dabei:

- welche Daten für das Training des ML Modells genutzt werden könnten,
- ob es sich um ein Problem des überwachten Lernens handelt, und wenn ja, ob es eine Regressions- oder Klassifikationsaufgabe darstellt,
- und wie die Performanz des Modells gemessen werden könnte.

Aufgabe 3 - Wahl der Fehlermetrik

In der Vorlesung haben wir den Mean Squared Error (MSE) als die übliche loss function für Regression kennengelernt. Angenommen Sie wollen die optimale lineare Funktion zu dem Datensatz in der folgenden Abbildung bzgl. MSE finden.



1. Wie könnte diese in etwa aussehen, wenn Sie die Ausreisser/Outlier unten rechts ignorieren? Zeichnen Sie Ihre Lösung ein.
2. Was ändert sich, wenn Sie die Ausreisser mit berücksichtigen?

3. Wie könnten Sie die Formel des MSE anpassen, um diesem Effekt etwas entgegen zu wirken?