

Fehlende Werte und Datenbereinigung

Kernaussagen

Fehlende Werte entstehen zum Beispiel durch Messfehler, manuelle Eingabefehler oder unvollständige Erhebungen.

Ein erster Schritt ist die Analyse, in welchen Spalten und wie häufig Werte fehlen.

Fehlende Werte können gelöscht, mit statistischen Werten ersetzt oder mit modellbasierten Verfahren imputiert werden.

Die Wahl der Strategie hängt davon ab, warum Werte fehlen und wie wichtig die betroffenen Variablen sind.

Saubere Datenbereinigung verbessert meist auch die Modelleistung.