

Data Science Process Model

Contents


- CRISP DM
- Kritik an CRISP-DM

Lernziele

- CRISP-DM als zentrales Prozess-Modell für Data Mining Projekte kennenlernen
- Mängel des CRISP-DM und Erweiterungen bzw. Alternativen benennen

CRISP DM

- Steht für *Cross-Industry Standard Process for Data Mining*
- **Methodologie:** Beschreibung von typischen Phasen und Aufgaben sowie ihren Beziehungen untereinander in einem Data Mining Projekt
- **Prozess-Modell:** Überblick über den Lebenszyklus eines Data Mining Projekts



Phasen eines Data Mining Projekts laut CRISP-DM.

Business Understanding

- Projektziele und -anforderungen aus geschäftlicher Sicht verstehen: was will die Kundin wirklich? Definiere Kriterien für den Geschäftserfolg.
- Welche Ressourcen sind verfügbar? Welche Risiken und Eventualitäten gibt es?
- Das Verständnis der geschäftlichen/fachlichen Ebene in eine Definition des Data-Mining-Problems übersetzen. Definiere Kriterien den technischen Erfolg
- Überführe das Wissen in einen vorläufigen Projektplan
- Relevanz von Business Understanding wird oft unterschätzt. Es geht nicht darum, ein tolles Modell zu erstellen, sondern ein Business Problem zu lösen
- Deployment sollte von Beginn an mitgedacht werden: Wie sollen Modelle geupdated werden? Wie soll die Übergabe an Kunden-IT stattfinden? Wie könnte Monitoring aussehen?
- Dafür auch nötig: Verständlichkeit / Plausibilität von Modellen
- Fairness & Privacy: benachteiligt mein Modell / Produkt bestimmte Personengruppen? Verletzt es die Privatsphäre einzelner? Ist Anonymisierung notwendig und sinnvoll?
- **Agiles Vorgehen:** Eine schnelle erste Iteration anstreben und Vorgehen / Ergebnisse zügig kommunizieren

Data Understanding

- Erste Datenerfassung
- Sich mit den Daten vertraut machen
- Datenqualität einschätzen
- Erste Erkenntnisse aus den Daten gewinnen (Exploration)

Task-Perspektive

- **Verständlichkeit:** Sind die Daten verständlich? Können wir sie interpretieren?
- **Nützlichkeit:** Sind die Daten für das angestrebte Ziel wertvoll?
- **Gültigkeit:** Handelt es sich um valide Daten? Sind die Quellen überprüfbar?
- **Glaubwürdigkeit:** Passen die Daten zu unseren Erfahrungen?
- **Exaktheit:** Sind die Daten präzise? Sind sie widerspruchsfrei und vollständig?
- **Aktualität:** Sind die Daten aktuell?
- **Volatilität:** Spannen die Daten einen ausreichenden Zeitraum? (Daten können gewisse Periodizität aufweisen)

Daten-Perspektive

- Was **bedeuten** die Werte der jeweiligen Attribute? Sind die Werte sinnvoll?
- Sind die Daten **plausibel**? Sind sie **widersprüchlich**?
- Sind die Daten **fehlerhaft**?
- **Fehlen Werte** bei den Attributen? Steckt in der Tatsache, dass ein bestimmter Wert fehlt, eine Information?
- Sind die Daten **repräsentativ** für das zu analysierende Problem? Gute Analysen nur dann möglich, wenn das reale Spektrum der Attribute und ihrer Werte in den Daten signifikant vertreten ist.

Data Preparation

Daumenregel besagt, dass **Datenvorverarbeitung ca. 80% der Arbeit** in einem Data Mining einnimmt



- Daten auswählen: welche Datensätze sollen verwendet werden? Gründe für die Einbeziehung/ Ausschluss dokumentieren.
- Daten bereinigen: Dies ist oft die zeitaufwändigste Aufgabe - andernfalls gilt oft "Garbage-in, garbage-out"
- Typische Schritte bei der Bereinigung: Korrigieren, Imputieren oder Entfernen fehlerhafter/fehlender Werte
- Daten durch neue Attribute anreichern
- Daten aus mehreren Quellen kombinieren
- Daten transformieren

Modeling

Erstellung und Bewertung verschiedener Modelle auf der Grundlage mehrerer Modellierungstechniken:

- **Bewertungsmetriken spezifizieren:** mit welchen Metriken soll der technische Erfolg gemessen werden? Wann ist ein Modell besser als ein anderes? Wann ist es gut genug?
- **Auswahl der Modellierungstechniken:** welche Algorithmen sollen zum Einsatz kommen?
- **Testdesign:** Je nach Problemstellung und Modellierungsansatz müssen die Daten möglicherweise in Trainings-, Test- und Validierungssätze aufteilen.

- **Modell erstellen:** Mit Hilfe der vorhandenen Daten das Modell finden, welches am besten das vorliegende technische Problem löst. (Manchmal nur 1-2 Zeilen Code!)
- **Modelle bewerten:** Modellergebnisse auf der Grundlage von Fachwissen, vordefinierten Erfolgskriterien und dem Testdesign interpretieren.

Evaluation

- **Ergebnisse bewerten:** Erfüllen die Modelle die Kriterien für den **Geschäftserfolg**? Welche Modelle sollten weiter empfohlen werden?
- **Prozess überprüfen:** Wurde etwas übersehen? Wurden alle Schritte ordnungsgemäß ausgeführt? Ergebnisse zusammenfassen und gegebenenfalls korrigieren.
- **Nächste Schritte festlegen:** Soll mit dem Deployment fortgefahren werden? Sollen weitere Iterationen durchgeführt werden?

Deployment

- Je nach Aufgabe kann es sich bei dem Ergebnis um einen Bericht, ein Dashboard, einen Prototypen / Proof of Concept oder ein Software-Produkt handeln
- Abhängig davon wird ein DEployment-Plan, möglichst früh im Projekt, entwickelt und umgesetzt
- Monitoring und Manitenance müssen dabei eine Rolle spielen

Kritik an CRISP-DM


- CRISP-DM existiert seit 1996 und ist das am meisten genutzte Vorgehensmodell für analytics / data mining Industrie-Projekte

- Es wird jedoch seit einigen Jahren nicht mehr gewartet, da es einige wichtige Themen nicht adäquat berücksichtigt
- CRISP-DM wurde entwickelt für Data Mining Projekte, und Data Science umfasst viel mehr. Dennoch kann man argumentieren, dass es gut adaptiert werden kann, denn alle DS Projekte starten mit Business Understanding, nutzen Daten, die prozessiert werden müssen, und wenden Modellierungsalgorithmen an.
- Struktur von CRISP-DM etwas starr: ähnliche Schwächen wie Wasserfall; kann schnelle Iterationen behindern.
 - Empfehlung: Agile Iterationen planen, vertikal denken!
- Dokumentation in nahezu jeder Aufgabe vorgesehen, nach vorgegebener Struktur.
 - Empfehlung: Eigene Arbeit weiterhin dokumentieren, da von entscheidender Bedeutung, aber in einem Maße, das tatsächliche Inkremente nicht behindert
- Ausgerichtet auf eine einzelne Person und nicht ein (agiles) Team.
 - Empfehlung: Integration moderner Projektmanagement-Methoden (Kanban Boards, SCRUM, Data-Driven SCRUM, Versionskontrolle, ...)
- Deployment wenig berücksichtigt, v.a. im Sinne moderner, Big Data Software
 - Empfehlung: aktuelle Technologien und Frameworks berücksichtigen (z.B. Cloud-Technologien); Einfluss des Deployments auf neu erhobene Daten berücksichtigen
- CRISP-DM deckt zahlreiche Aspekte nicht oder nur wenig ab. Dazu gehören: Fairness, Transparenz, Erklärbarkeit, Datenschutz, Anonymisierung, User-Interaktion, Stakeholder-Interaktion.
 - Empfehlung: berücksichtige aktuelle Handlungsempfehlungen zu diesen Themen.

Alternativen

- Es gibt mittlerweile verschiedene Erweiterungen von bzw. Alternativen zu CRISP-DM
- Eines davon ist *Microsoft's Team Data Science Process* (TDSP, siehe Abb.)

- Kombiniert Data Science Life Cycle, Software Engineering, und agile Prozesse
- Definiert 6 typische Team-Rollen in einem DS Projekt
- Hört nicht beim Deployment auf
- Wird gewartet und weiterentwickelt



Microsoft's Team Data Science Process [Quelle](#)