

Deskriptive und Explorative Datenanalyse

Contents

- Statistische Datentypen (Merkmalstypen)
- Statistische Analysen
- Aufgaben

Zentrale Schritte des Data Understanding

Lernziele

- Statistische Datentypen und ihre Unterteilung kennen
- Zentrale beschreibende Datenanalysen und -visualisierungen definieren

Statistische Datentypen (Merkmalstypen)


In der (deskriptiven) Statistik interessieren wir uns v.a. für **Merkmale (Variablen, Attribute)**, die gewisse **Ausprägungen (Werte)** haben.

Im Beispiel der Palmer Penguins Daten ist z.B. **Island** ein Merkmal, und es kann die Werte "Biscoe", "Dream" und "Torgersen" annehmen.

Folgende Fragen sollten zu jeder Variable beantwortet werden:

- Welchen Typ hat die Variable?
- Welche Operationen sind für die Variable erlaubt?
- Welche Analysen machen Sinn?
- wie müssen die Werte der Variable für Algorithmen aufbereitet werden (Stichwort: Feature Engineering)?
- Wie kann / sollte sie persistiert werden?

Diskussion (3-5 Min.): Welche Unterscheidungen sehen Sie bei den abgebildeten Attributen?



Unterteilung nach Anzahl der möglichen Ausprägungen

- **diskret: endlich viele** (z.B. Anzahl der Personen in einem Haushalt) oder **abzählbar unendlich viele** (Anzahl der Würfe bis zu einer Sechs) Werte möglich
- **stetig**: kann alle Werte eines Intervalls annehmen (z. B. Körpergröße)
- **quasi-stetig**: eigentlich stetig, aber durch Messauflösung oder Rundung diskret beobachtet (Zeit in s, Geld in Cent). In Analysen oft wie stetig behandelt.

Eigentlich ergeben Messungen an sich immer diskrete Werte, d.h. Variablen sind diskret oder quasi-stetig und werden als stetig behandelt.

Binning/Grouping: Stetige Merkmale werden für Übersicht/Plots manchmal zu Klassen zusammengefasst (z. B. Alter $\rightarrow$ " < 25 ", " ≥ 25 "). Das vereinfacht, verliert aber Information. Viele Algorithme (z. B. Entscheidungsbäume) finden Schwellwerte selbst und brauchen kein Vorab-Binning.

Unterteilung nach Bedeutung

- **qualitativ (kategorial):** beschreiben Kategorien/Eigenschaften (z. B. Farbe, Pinguin-Art)
 - **binär:** Spezialfall "nur zwei Ausprägungen" (Ja/Nein, 0/1).
- **quantitativ:** beschreiben Menge/Intensität (z. B. Länge, Masse, Preis)

Unterteilung nach Skalen

- **nominal-skaliert:**
 - Kategorien ohne Ordnung (z. B. Farben, Gebäude-Typen).
 - Aus technischen Gründen werden manchmal Werte durch Zahlen ersetzt (z.B. für ML-Algorithmen). Zahlen-Labels sind aber nur Codes, ohne Abstands-Bedeutung.
- **ordinal-skaliert:** geordnet, aber Abstände nicht interpretierbar (z.B. Schulnoten: 1 ist besser als 2 und 2 ist besser als 3 aber die Abstände sind nicht definiert).
- **metrisch (kardinal-skaliert):** Geordnet und Abstände interpretierbar (z.B. Temperatur, Kredithöhe)
 - **Intervall:** Abstände sinnvoll, Verhältnisse nicht (Nullpunkt willkürlich, z. B. $^{\circ}\text{C}$, Kalenderjahre).
 - **Verhältnis (Ratio):** Abstände und Verhältnisse sinnvoll, natürlicher Nullpunkt (z. B. Länge, Masse, Geld, Kelvin).

Verhältnis zwischen den jeweiligen Skalen

- nominal/ordinal → qualitativ → immer diskrete Ausprägungen.
- metrisch → quantitativ → können diskret (Cent) oder (quasi-)stetig sein.

Strukturierte vs. unstrukturierte Daten

- **Strukturiert:** Tabellarische Daten mit festem Schema/Datentypen (im Sinne von Datenbanken - denken Sie an SQL oder Excel; Datentypen z. B. Farbe als Kategorie, Gewicht als Zahl, Erstellungsdatum als Datum).
- **Semi-strukturiert:** Tragen Strukturinfos, aber nicht streng tabellarisch (JSON, XML, Logs). Zuerst parsen/normalisieren, dann tabellarisieren.
- **Unstrukturiert:** Kein vorgegebenes Schema (Freitext, Bilder, Audio). Erfordert sog. **Feature-Extraktion** (bei Bildern z. B. SW- oder RGB-Zahl pro Pixel; Text z. B. Tokenisierung und Repräsentationen über Bag-of-Words).

Diskussion (3-5 Min.): Wie können die Attribute des Palmer Penguins Datensatzes kategorisiert werden?

► Palmer Penguins Attribute

Skala	Beispiele	Ordnung?	Abstände?	Verhältnisse?
Nominal	Species	Nein	Nein	Nein
Ordinal	Stage (hier 1 Wert)	Ja	Nein	Nein
Metrisch - Intervall	Delta 15 N (o/oo)	Ja	Ja	Nein
Metrisch - Verhältnis	Body Mass (g)	Ja	Ja	Ja
Unstrukturiert	Comments	-	-	-

Praxis-Hinweise

- Identifier vs. Variablen: Sample Number, Individual ID sind IDs (nominal) und i. d. R. keine erklärenden Attribute.
- Temporal: Date Egg als Datum behandeln und abgeleitete Variablen bilden (Monat, Woche, Jahreszeit, "Tag im Jahr").
- Ordinal korrekt kodieren: Als geordnete kategorische Variable behandeln; keine Mittelwerte über Codezahlen bilden.

Statistische Analysen

Häufigkeiten

Sei n die Anzahl der Datenpunkte und sei X ein Merkmal mit den Werten $x_1, \dots, x_n$. Um die Daten so gut wie möglich zusammenzufassen, betrachten wir verschiedene statistische Größen:

- **absolute Häufigkeit** a_j : **Anzahl** der Datenpunkte, für welche die Variable x die Ausprägung x_i hat
- **relative Häufigkeit** r_j : **Anteil** der Datenpunkte, für welche die Variable x die Ausprägung x_i hat

$$r_j = \frac{a_j}{n}$$

Ist X eine qualitative Variable, so ist die Anzahl k der verschiedenen Ausprägungen der Variable X häufig viel kleiner als n (z.B. Anzahl verschiedener Werte einer Variable für Farben). Bei quantitativen Variablen ist k üblicherweise nah bei n .

- $a_1, \dots, a_k$: **absolute Häufigkeitsverteilung**

- $r_1, \dots, r_k$: **relative Häufigkeitsverteilung**

Show code cell source

```
import pandas as pd
from os.path import join

penguins = pd.read_csv(join('data', 'penguins_lter.csv'))
```

```
# Absolute Häufigkeiten der Spalte `Island`
penguins['Island'].value_counts(dropna=False)
```

```
Island
Biscoe      168
Dream       124
Torgersen    52
Name: count, dtype: int64
```

```
# Relative Häufigkeiten der Spalte `Island`
penguins['Island'].value_counts(normalize=True, dropna=False)
```

```
Island
Biscoe      0.488372
Dream       0.360465
Torgersen    0.151163
Name: proportion, dtype: float64
```

- Die absoluten und relativen Häufigkeiten zu einer Variable können in einer sog. **Häufigkeitstabelle** zusammengefasst werden.

- Achtung: ohne zusätzliche Gruppierung nicht sinnvoll für Merkmale mit vielen verschiedenen Ausprägungen.

Graphische Darstellung

Kategorische (qualitative) Merkmale


- **Säulendiagramm:** x -Achse repräsentiert die Werte $x_1, \dots, x_k$ der Variable X . Über jedem Wert x_i ein Rechteck mit Höhe a_i (bzw. r_i). Breite der Balken gleich für alle Werte von X .
- **Balkendiagramm:** wie Säulendiagramm, mit dem Unterschied, dass die Ausprägungen von X auf der y-Achse aufgetragen werden.
- **Kreisdiagramm:** Flächen der Kreissektoren proportional zu den Häufigkeiten

```
import sys, os
sys.path.append(os.path.abspath("src"))
from ds_helpers.plotting import setup_plots, wrap_labels
setup_plots()
```

Show code cell source

```
fig, ax = plt.subplots(1, 1, figsize=(10, 3.6), constrained_layout=True)


sns.countplot(data=penguins, x="Species", order=species_order, ax=ax)
ax.set_title("Säulendiagramm")
ax.set_xlabel("Art")
ax.set_ylabel("Anzahl");
wrap_labels(ax, axis="x", width=12)
```

**Show code cell source**


```
species_order = sorted(penguins["Species"].dropna().unique())
sex_vals = penguins["Sex"].dropna().unique()
sex_order = ["female", "male"] if set(sex_vals) == {"female", "male"} else sorted(sex_vals)
```


Show code cell source

```
fig, ax = plt.subplots(1, 1, figsize=(10, 3.6), constrained_layout=True)
sns.countplot(data=penguins, y="Sex", order=sex_order, ax=ax)
ax.set_title("Balkendiagramm")
ax.set_xlabel("Anzahl")
ax.set_ylabel("Geschlecht")
for cont in ax.containers:
    ax.bar_label(cont, fmt="%d", padding=3)
plt.show();
```



```
fig, ax = plt.subplots(1, 1, figsize=(5, 5), constrained_layout=True)
penguins['Island'].value_counts().plot(kind='pie', ax=ax)
plt.title('Kreisdiagramm');
```





Quantitative Merkmale

Bei quantitativen Merkmalen (metrisch oder ordinalskaliert) mit vielen Ausprägungen ergeben die obigen Darstellungstypen in der Regel wenig Sinn, da es zu viele verschiedene Ausprägungen gibt. Stattdessen werden v.a. **Histogramme** verwendet.


- graphische Darstellung der Verteilung einer numerischen Variable
- die Werte der Variable werden in Intervalle gruppiert, und die Anteil pro Intervall entspricht der Balkenfläche

Show code cell source


```
# Absolute values
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(10, 3.6), constrained_layout=True)
sns.histplot(penguins['Body Mass (g)'], stat="count", bins=20, ax=ax1)
sns.histplot(penguins['Body Mass (g)'], stat="count", bins=5, ax=ax2)
ax1.set_title('20 Intervalle'); ax2.set_title('5 Intervalle')
ax1.set_xlabel('Body Mass (g)'); ax1.set_ylabel('Anzahl')
ax2.set_xlabel('Body Mass (g)'); ax2.set_ylabel('Anzahl')
plt.show()
```

**Show code cell source**


```
# Density
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(10, 3.6), constrained_layout=True, sharey=True)
sns.histplot(penguins['Body Mass (g)'], stat="density", kde=False, bins=20, ax=ax1)
sns.histplot(penguins['Body Mass (g)'], stat="density", kde=False, bins=5, ax=ax2)
ax1.set_title('20 Intervalle'); ax2.set_title('5 Intervalle')
ax1.set_xlabel('Body Mass (g)'); ax1.set_ylabel('Anzahl')
ax2.set_xlabel('Body Mass (g)'); ax2.set_ylabel('Anzahl')
plt.show()
```



Typische Verteilungen



Vergleich von Variablen möglich



Beschreibung univariater Verteilungen

Graphische Darstellungen geben einen ersten Eindruck über die Häufigkeitsverteilungen. Für metrische Merkmale können jedoch **weitere statistische Maßzahlen** herangezogen werden, um Fragen folgender Art zu beantworten:

- Wo liegt das **Zentrum** der Daten?
- Wie stark **streuen** die Daten um das Zentrum?
- Ist die Verteilung **symmetrisch** oder **schief**?

- Gibt es **Ausreißer**?

Symmetrie und Schiefe

Wir werden die Begriffe **Symmetrie** und **Schiefe** für Häufigkeitsverteilungen (zunächst) nicht mathematisch exakt definieren. Aktuell reicht uns eine 'visuelle' Begriffsbestimmung.


Eine Verteilung heißt **symmetrisch**, wenn es eine Symmetrieachse gibt, so dass die rechte und die linke Hälfte der Verteilung annähernd zueinander spiegelbildlich sind. Eine deutlich unsymmetrische Verteilung heißt **schief**.

Eine Verteilung heißt **linkssteil** (bzw. **rechtssteil**), wenn der überwiegende Teil der Daten linksseitig (bzw. rechtsseitig) konzentriert ist.

Show code cell source

```
from scipy.stats import skewnorm
fig, ax = plt.subplots(1, 3, figsize=(10,3.6), sharey=True)

dist_1 = skewnorm.rvs(4, scale=400, loc=400, size=2000)
dist_2 = skewnorm.rvs(0, size=2000)
dist_3 = skewnorm.rvs(-10, scale=10, loc=5, size=2000)
titles = ['linkssteil', 'symmetrisch zu  $x=0$ ', 'rechtssteil']
for i, dist in enumerate([dist_1, dist_2, dist_3]):
    ax[i].hist(dist, histtype='bar', alpha=0.8, bins=15)
    ax[i].set_title(titles[i]);
plt.tight_layout()
```

Wie helfen uns Symmetrie und Schiefe bei der Beschreibung der zugrundeliegenden Daten?

Stellen wir uns vor, die Abb. oben links stellt die Verteilung von Nettomieten einer Stadt wie Berlin dar. Wohnungen mit einer Miete zwischen 500 und 800 Euro sind somit die häufigsten. Die Häufigkeiten nehmen nach links steiler ab als nach rechts. Das bedeutet, im höheren Preisbereich streuen die Mietpreise stärker, die "durchschnittlichen" Mieten liegen somit links von der Mitte des Diagramms.

Lagemaße

Lagemaße oder Lageparameter sind Zahlenwerte, die das Zentrum einer Häufigkeitsverteilung beschreiben, z.B.:

- mittlere Schlafdauer einer bestimmten Personengruppe

- Durchschnittstemperatur in einer Region
- die Häufigste Abschlußnote im Studienfach Informatik

Welches Lagemaß sinnvoll ist, hängt von der Fragestellung, der Datenlage sowie vom Skalenniveau (nomninal/ordinal/metrisch) des Merkmals ab.

Modus

- Jede Merkmalsausprägung, die **am häufigsten vorkommt**, heißt ein Modus der Stichprobe.
- Der Modus lässt sich für alle Typen von Variablen definiert.
- Der Modus ist das wichtigste Lagemaß für kategorielle Merkmale. In Darstellungen mit Säulen- oder Balkendiagrammen ist es der Wert mit dem größten Balken.
- Der Modus ist umso aussagekräftiger je dominanter eine Ausprägung ist.

Manchmal kann es sinnvoll sein, die kummulierte Summe der nach Häufigkeit sortierten Werte zu betrachten. In Fällen, in denen der Modus nicht besonders hoch ist, kann es dennoch sein, dass zwar nicht einer aber doch nur wenige Werte bereits den Großteil der Datenpunkte abdecken.

Arithmetische Mittel

Bekanntestes Lagemaß, auch **Mittelwert** genannt (engl. *mean*).

$$\bar{x} = \frac{1}{n}(x_1 + \dots + x_n)$$

Der Mittelwert ist streng genommen nur für metrische Merkmale sinnvoll, d.h. geordnete Merkmale mit sinnvollem Abstandsbegriff. Er wird jedoch teilweise auch für ordinalskalierte Merkmale wie Schulnoten verwendet.

Alle Werte gehen mit der gleichen Gewichtung ($\frac{1}{n}$) in die Berechnung des Mittelwerts ein. Somit ist der **Mittelwert**

empfindlich wird gegenüber sog. Ausreißern, insbesondere bei geringer Fallzahl (kleines n).

Median

Lagemaße, die nicht so empfindlich gegenüber Ausreißern sind, werden als **resistent** oder **robust** bezeichnet.

Wichtigstes Beispiel ist der **Median**. Um diesen Wert zu berechnen, ordnen wir die Werte der Größe nach. Der Median ist, grob gesagt, derjenige Wert, so dass eine Hälfte der Werte unterhalb und eine andere oberhalb liegt.

$$x = 2, 3, 4, \mathbf{6}, 7, 7, 8 \implies \text{Median}(x) = 6$$

$$y = 2, 3, \mathbf{4}, \mathbf{6}, 7, 7 \implies \text{Median}(y) = \frac{4 + 6}{2} = 5$$

- Median kann als Lagemaß für **ordinalskalierte und metrische Merkmale** verwendet werden
- Bleibt unverändert, wenn sich z.B. der höchste Wert erhöht, während der Mittelwert sich ggf. stark erhöhen würde
- Leicht zu interpretieren: Ist man z. B. auf der Suche nach einer Wohnung, so sagt der Median, dass 50% der Wohnungen günstiger und 50% teurer sind


Diskussion (3–5 Min.)

Wo liegen der Median und Modus im Verhältnis zum Mittelwert (rote Linie)?


Show code cell source

```
from scipy.stats import skewnorm
fig, ax = plt.subplots(1, 3, figsize=(12,5), sharey=True)

dist_1 = skewnorm.rvs(15, scale=400, loc=400, size=1000)
dist_2 = skewnorm.rvs(0, size=1000)
dist_3 = skewnorm.rvs(-10, scale=10, loc=5, size=1000)
titles = ['linkssteil', 'symmetrisch zu  $x=0$ ', 'rechtssteil']
for i, dist in enumerate([dist_1, dist_2, dist_3]):
    ax[i].hist(dist, histtype='bar', alpha=0.8, bins=10)
    ax[i].axvline(x=np.mean(dist), color='r', lw=2)
    ax[i].set_title(titles[i]);
plt.tight_layout()
```



► **Verhältnis der Lagemaße in Abhängigkeit der Schiefe der Verteilung**



Lagemaße auf gruppierten Daten


Teilweise ist es sinnvoll, Daten zu gruppieren und **Lagemaße pro Gruppe** zu berechnen. Es kann beispielsweise von Interesse sein, **wie stark das gewählte Lagemaß in den einzelnen Gruppen von dem der gesamten Gruppe abweicht**.

Graphisch sieht dies beispielsweise folgendermaßen aus:

Show code cell source

```
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12,5), sharey=True)
fig.suptitle("Abweichung des Mittelwerts und Medians pro Jahreszeit", fontsize=20)
mean_g, median_g = penguins['Body Mass (g)'].mean(), penguins['Body Mass (g)'].median()
penguins[['Island', 'Body Mass (g)']].groupby('Island').agg(lambda x: x.mean() - mean_g).plot(kind='line')
penguins[['Island', 'Body Mass (g)']].groupby('Island').agg(lambda x: x.median() - median_g).plot(kind='line')
ax1.axvline(x=0, color='r', lw=2); ax2.axvline(x=0, color='r', lw=2);
```

Abweichung des Mittelwerts und Medians pro Jahreszeit



Quantile

Quantile stellen eine **Verallgemeinerung des Medians** dar; dieser wird auch als das 0,5-Quantil oder 50%-Quantil bezeichnet, weil er die Mitte innerhalb der geordneten Wertemenge darstellt. Um beispielsweise sog. **Quartile** (25% - 50% - 75%) zu berechnen, wird die geordnete Wertemenge in 4 "gleich große" Teile aufgeteilt. (Es ist eine Frage der

Definition, welcher Randpunkt das Quantil sein soll, ist für uns aber nicht wichtig).

Definition (Quantil)

Sei $0 < p < 1$. **Jeder Wert** x_p , für den mindestens ein Anteil p der Daten $\leq x_p$ und mindestens ein Anteil $1 - p$ der Daten $\geq x_p$ ist, heißt p -Quantil.

Verteilungen werden häufig mit Hilfe der **Fünf-Punkte-Zusammenfassung** beschrieben, bestehend aus:

- $x_{\min}$: der kleinste Wert der Verteilung
- Q_1 oder $x_{0.25}$: unteres Quartil (0.25-Quantil)
- Median (0.5-Quantil)
- Q_3 oder $x_{0.75}$: oberes Quartil (0.75-Quantil)
- $x_{\max}$: der größte Wert der Verteilung

Diese Werte teilen den nach Größe geordneten Datensatz in vier Teile ein, wovon jeder ca. **ein Viertel der Daten** enthält.

Ist z.B. die Verteilung annähernd symmetrisch zum Median, so sind $x_{0.25}$ und $x_{0.75}$ ähnlich weit weg vom Median entfernt. Liegt $x_{0.25}$ weiter entfernt vom Median als $x_{0.75}$, so weist das auf eine rechtssteile Verteilung hin.

Für metrische Merkmale gibt der sog. **Interquartilsabstand (IQR)**, definiert als $d_q = x_{0.75} - x_{0.25}$,


Aufschluß darüber, wie weit die Verteilung auseinander gezogen ist.

Eine grobe **Faustregel zur Identifikation von Ausreißern** ist wie folgt: Werte, welche außerhalb des Intervalls

$$[x_{0.25} - 1.5 * d_Q, x_{0.75} + 1.5 * d_Q]$$

liegen, sind gute Ausreißer-Kandidaten, die genauer inspiziert werden sollten.


Die Fünf-Punkte-Regel lässt sich durch den sog. **Box-Plot** visualisieren:



Show code cell source

```
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12,5), sharey=True)
penguins.boxplot(column='Body Mass (g)', ax=ax1);
penguins.boxplot(column='Body Mass (g)', by='Island', ax=ax2);
fig.suptitle("Boxplot der Variable `Body Mass (g)`", fontsize=20);
```

Boxplot der Variable `Body Mass (g)`



Streuungsmaße

Varianz und Standardabweichung

- Maßzahlen für die Streuung der Werte einer numerischen Variable
- Betrachtet alle Werte
- **Varianz = mittlere quadratische Abweichung der Werte vom Mittelwert**
- **Standardabweichung = Quadratwurzel der Varianz**

Die **Varianz** der Werte $x_1, \dots, x_n$ ist gegeben durch

$$\sigma^2 = \frac{1}{n} \left((x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \right) = \sum_{i=1}^n (x_i - \bar{x})^2.$$

Die **Standardabweichung** ist die Wurzel der Varianz:



$$\sigma = +\sqrt{\sigma^2}.$$


Zugrundeliegende Idee

- Die Werte $(x_i - \bar{x})$ in σ^2 messen, wie weit die Werte x_i von dem Mittelwert $\bar{x}$ entfernt sind.
- Die Abweichungen können sowohl positiv als auch negativ sein; durch das Quadrieren werden alle Abweichungen positiv.
- Quadrieren: große Abweichungen werden noch größer, kleine Abweichungen (nahe bei Null) werden kleiner.
- Varianz groß, wenn Daten stark um den Mittelwert streuen.

Show code cell source

```
fig, ax = plt.subplots(3, 1, figsize=(12,8), sharex=True)
x1 = [65,75,73,50,60,64,69,62,67,85]
x2 = [85, 79, 57, 39, 45, 71, 67, 87, 91, 49]
x3 = [43, 51, 53, 110, 50, 48, 87, 69, 68, 91]
for i, x in enumerate([x1, x2, x3]):
    ax[i].scatter(x, y=[0 for i in range(len(x))])
    ax[i].axvline(np.mean(x), color='r', lw=2)
    ax[i].axvline(np.mean(x) - np.std(x), color='r', lw=2, linestyle='dashed')
    ax[i].axvline(np.mean(x) + np.std(x), color='r', lw=2, linestyle='dashed');
    ax[i].set_yticklabels([])
```





Korrelation

- allgemein: irgendeine statistische Beziehung zwischen zwei Zufallsvariablen
- meistens messen wir damit den Grad der **linearen Beziehung** zweier Variablen
- Beispiel: physische (z.B. Größe) oder gesellschaftliche (z.B. Bildungsgrad) Eigenschaften der Eltern und ihrer Kinder
- Korrelationen sind sinnvoll, da sie häufig ein Indiz für Vorhersagbarkeit sind
- Es gibt verschiedene **Korrelations-Koeffizienten** für die Quantifizierung von Korrelation
- Häufigste ist der Pearson correlation coefficient; dieser erkennt nur lineare Beziehungen (die vorhanden sein können, auch wenn die eigentliche Beziehung komplexer ist, z.B. quadratisch)
- Andere Korrelations-Koeffizienten sind robuster und funktionieren besser bei nicht-linearen Beziehungen

Pearson correlation coefficient (PCC)

Seien X und Y zwei Zufallsvariablen mit Erwartungswerten μ_X und μ_Y und Standardabweichungen σ_X und σ_Y . Der Pearson Korrelations-Koeffizient ist definiert als

$$\rho_{XY} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$





Wir haben es in der Regel mit Stichproben einer Zufallsvariable zu tun. Der Sample Pearson Correalation Coefficient ist ein Schätzer des PCC und berechnet sich wie folgt:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y}$$

wobei

$$s_x^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

die empirische Standardabweichung darstellt.



Vier Datensätze mit dem gleichen Koeerlationskoeffizienten (0,816)

Aufgaben

Aufgabe 1

Skizzieren Sie einen Boxplot, bei dem die zugrundeliegenden Daten linkssteil / rechtssteil / symmetrisch sind.

Aufgabe 2

Arbeiten Sie das Notebook [Teil 2 der Einführung in Python](#) durch.