


Einführung in Maschinelles Lernen

Contents

- Zentrale Begriffe des ML
- Wofür Machine Learning
- Unterscheidung von ML Ansätzen

Lernziele

- Zentrale Begriffe wie Lernen, Modell, und Training kennenlernen
- Verstehen, wofür Maschinelles Lernen (= Machine Learning = ML) eingesetzt wird
- Dimensionen zur Unterscheidung von ML kennenlernen



Zentrale Begriffe des ML

- Umwandlung von **Erfahrung** in **Kenntnisse oder Wissen**.
- Der **Input** eines Lernalgorithmus sind **Daten**, die Erfahrung darstellen.
- Der **Output** ist Wissen/Expertise, normalerweise in Form eines **Programms**, das eine bestimmte (komplexe) Aufgabe erfüllen kann
- Wenn wir die Parameter des Programms festgelegt haben, sprechen wir von einem **Modell**. Die Menge aller solchen Programme, die durch eine Festlegung der Parameter entstehen, nennen wir eine **Modell-Familie** oder

Familie von Modellen. (In der Mathematik spricht man allgemein von Familien von Funktionen, z.B. wenn diese sich als geschlossene Formel in Abhängigkeit eines Parameters formulieren lassen, z.B. $f_a(x) = a \cdot \sin(x)$).

- Beispiel: Die Menge aller **linearen Funktionen**

$$f(x_1, \dots, x_n) = a_0 + a_1x_1 + \dots + a_nx_n,$$

wobei $x_1, \dots, x_n$ **Attribute unserer Daten** sind und $a_0, \dots, a_n$ die **zu lernenden Parameter**.

- Das **“Meta-Programm”**, welches wir verwenden, um die optimalen Parameter zu finden, heißt **Lern-Algorithmus** oder **Lernverfahren (learning algorithm)**.
- Emails sind der sog. **Input (Eingabe)** (für den Lern-Algorithmus und die Modelle), die Kategorien **Spam** und **nicht-Spam** sind der sog. **Output (Ausgabe)**.
- Das Finden der “besten” Parameter in einer Modell-Familie mit Hilfe der gesammelten Daten ist das sog. **Training** oder **Modell-Training**.

Anmerkung: Nicht alle ML Modelle sind in diesem Sinne parametrisierbar.


Wofür Machine Learning

Machine Learning (ML) ist zu einem Standardwerkzeug für viele Aufgaben geworden, bei denen **Informationen aus Daten extrahiert** werden müssen.

- Daten: Rohinformationen
- Information: Daten mit Kontext, verarbeitet, Wert

Machine Learning kommt v.a. zum Einsatz bei Aufgaben, die wir mit einer **expliziten Abfolge von Regeln** nicht gut lösen können.

Beispiel: Objekterkennung in Bildern





Objekterkennung auf Bildern (Bereich und Kategorie des Objekts)

- Wir wissen nicht, wie wir ein solches Programm schreiben sollen, **da wir nicht wissen, wie unser Gehirn Objekte erkennt**
- Selbst wenn wir einen Regelbasierten Ansatz hätten, wäre er vermutlich extrem komplex
- Ähnliches gilt für Autonomes Fahren, Spracherkennung


Ein Programm für **sich schnell ändernde Aufgaben** zu schreiben, wie z.B. die Berechnung der **Wahrscheinlichkeit für Kreditkartenbetrug**, ist ebenfalls sehr schwer:

- Es gibt vermutlich keine Regeln, die gleichzeitig einfach und zuverlässig sind. Wir müssten eine große Menge schwacher Regeln kombinieren
- Betrug ist ein "bewegtes Ziel": Betrüger*innen ändern ihre Methoden, das Programm müsste also **kontinuierlich angepasst** werden

Manche Aufgaben **gehen über menschliche Fähigkeiten hinaus**, z.B. wenn das Ziel die **Analyse großer, komplexer Daten** wie:

- Daten in der Astronomie
- Medizinisches Wissen aus medizinischen Archiven extrahieren
- Wetter-Vorhersage
- Analyse von Genomdaten
- Web-Suchmaschinen

Beispiel: Vorhersage des Effekts einzelner Aminosäure-Mutationen in Proteinen




Vorhersage des Effekts von Missense-Varianten mit Hilfe des AlphaMissense Modells. [Quelle: Jun Cheng et al. \(2023\)](#)

ML Verfahren sind also besonders dann sinnvoll, wenn:

- Probleme nicht mit Hilfe von wenigen, einfachen und zuverlässigen Regeln gelöst werden können
- Wir die Lösung des Problems gar nicht genau kennen (Bsp.: Bilderkennung)
- Zu erwarten ist, dass sich die Daten häufig ändern werden (Bsp.: Kreditkartenbetrug)
- Implementierung eines klassischen Programms sehr zeitintensiv ist
- Der Mensch das Problem selbst gar nicht lösen kann
- "Genügend gute" Daten vorhanden sind, aus denen "gelernt" werden kann!

Beispiel: wake word

Sprach-basierte Assistenten wie Alexa oder Siri werden über ein sog. *wake word* aktiviert (z.B. "Alexa" oder "Hey Siri").



Diskussion (3–5 Min.)

Wie könnte man ein Programm schreiben, welches das 'wake word' erkennt (Programmiersprache egal)?

► (Un-)mögliche Lösung

Dies ist ein sehr schweres Problem. Es ist unmöglich Regeln zu formulieren, um das Audio-Signal zuverlässig und robust zu verarbeiten und zu klassifizieren.

Alternative:

- Wir können **viele** Audio-Dateien und zugehörige Labels (yes, no) sammeln.
- Wir definieren eine **geeignete Metrik**, um die Performanz von Programmen zu **messen** (z.B. Anteil der korrekt erkannten Wörter)
- Wir definieren ein **flexibles Programm**, welches von verschiedenen **Parametern** abhängt, und verwenden die gesammelten Daten, um die **optimalen Parameter** zu finden, d.h. diejenigen Parameter, welche im Sinne der gewählten Metrik die besten Ergebnisse erzielen.
- Wir definieren für diese **Lernaufgabe** ein geeignetes Verfahren.

Unterscheidung von ML Ansätzen

ML Ansätze lassen sich entlang verschiedener Dimensionen unterscheiden:

Supervised vs. Unsupervised Learning (überwacht vs. unüberwacht)

Beispiel: Klassifizierung von Spam-E-Mails vs. Erkennung von Anomalien in Emails

Beispiel: Erkennung von Spam-E-Mails:

- Beim überwachten Lernen wird ein Algorithmus auf **Trainingsdaten**, die aus E-Mails bestehen, die als **Spam** bzw. **Nicht-Spam** (Klassen, Kategorien) **gekennzeichnet** sind, **trainiert**, der **ungesehene** E-Mails als **Spam** bzw. **Nicht-Spam** klassifizieren kann.
- Beim unüberwachten Lernen erhält der Lernalgorithmus einen großen Datensatz von E-Mails **ohne Kennzeichnung** und soll "ungewöhnliche" E-Mails erkennen.

Es gibt auch Zwischenformen, sowie das verstärkende Lernen (Reinforcement Learning).

Active vs. Passive Learning

- Ein aktiver Lernalgorithmus **interagiert zur Trainingszeit** mit der Umgebung, indem er z.B. Abfragen formuliert oder Experimente durchführt.
- Ein passiver Lernalgorithmus verarbeitet die Informationen, die ihm von der Umgebung (in Form von Trainingsdaten) zur Verfügung gestellt werden.

Beispiel: Spam-Filter


- typischerweise passiv: wird anhand von E-Mails trainiert, die **zuvor** von Nutzer*innen als Spam bzw. nicht-Spam gelabelt (annotiert) wurden
- die aktive Form wäre, wenn der Algorithmus die Benutzerin auffordert, *bestimmte* E-Mails zu kennzeichnen. (Es gibt Verfahren, entsprechende E-Mails auszuwählen.) Der Lernalgorithmus könnte sogar selbst E-Mails *erzeugen* und sie dann kennzeichnen.

Online vs. Batch Learning

- Batch: Lernalgorithmus lässt zunächst eine große Menge an Trainingsdaten verarbeiten, um zu lernen, und wendet erst **danach** das gelernte Wissen an
- Online: Der Lernalgorithmus muss **während des Trainings reagieren**, d. h. er wird ständig aktualisiert (typischerweise bei Datenströmen oder wenn die Datenmenge zu groß für den Speicher ist oder zeitliche Änderungen auftreten; Beispiel: Echtzeit-Empfehlungen)




..



Online update

model at time t



Unser Fokus liegt auf:

1. **Supervised und Unsupervised Learning**
2. **Batch Learning**
3. **Passive Learning**