

Metriken zur Bewertung von Modellen

Contents

- Fehler vs. Score
- Klassifikation
- Regression
- Aufgaben

Fehler vs. Score

- **Fehler (Error)** ist ein Maß für die Abweichung der Vorhersagen eines Modells von den tatsächlichen Werten. Es gilt: je niedriger desto besser.
- **Score** ist ein Maß für die Leistung eines Modells. Es gilt: je höher desto besser.
- Für beide sind die Werte oftmals zwischen 0 und 1 skaliert, können aber auch andere Bereiche haben.
- Fehlermaße sind nützlich, um die Genauigkeit der Vorhersagen zu bewerten, während Score-Maße oft verwendet werden, um die Gesamtleistung eines Modells zu beurteilen.
- Die Wahl zwischen Fehler- und Score-Maßen hängt von der spezifischen Anwendung und den Anforderungen des Modells ab.

Klassifikation

Genauigkeit (Accuracy)

- Die Genauigkeit ist ein Score, der den Anteil der korrekt vorhergesagten Instanzen an der Gesamtzahl der Instanzen angibt.
- Sie ist das einfachste Maß für die Leistung eines Klassifikationsmodells.
- Allerdings kann die Genauigkeit irreführend sein, wenn die **Klassen unausgewogen** (engl. **skewed**) sind, oder die **Fehlerarten unterschiedliche Relevanz** haben.

Beispiel: Fraud Detection (Betrugserkennung)

- Angenommen, wir trainieren ein ML Modell auf einem Datensatz von 1000 Bank-Transaktionen, der nur 10 Betrugsversuche beinhaltet
- Das Modell, welches immer "kein Betrug" vorhersagt, hätte eine Genauigkeit von $990/1000 = 0.99$, obwohl es keinen einzigen Betrugsversuch korrekt identifiziert hat.
- (Entsprechend gilt auch, dass man die Loss Function anpassen müsste, um solche Fälle zu berücksichtigen)

Ein binärer Klassifikator, z.B. für Fraud Detection, kann grundsätzlich 2 Arten von Fehler machen:

- **Falsch-Positiv** (engl. **False Positive, FP**): Eine reguläre Transaktion wird als Betrug klassifiziert
- **Falsch-Negativ** (engl. **False Negative, FN**): Ein Betrug wird nicht erkannt und stattdessen als reguläre Transaktion klassifiziert

Confusion Matrix

- Die **Confusion Matrix** ist eine Tabelle, die die Fehlerarten und die Leistung eines Klassifikationsmodells

zusammenfasst.

- Sie zeigt die tatsächlichen Klassen gegen die vorhergesagten Klassen.

CONFUSION MATRIX
(WAHRHEITSMATRIX)

		WAHRE KLASSE	
		BETRUG	KEIN BETRUG
VORHERGESAGTE KLASSE	BETRUG	3	4
	KEIN BETRUG	2	127

		WAHRE KLASSE	
		POSITIV P	NEGATIV N
VORHERGESAGTE KLASSE	POSITIV P	TRUE POSITIV TP	FALSE POSITIV FP
	NEGATIV N	FALSE NEGATIV FN	TRUE NEGATIV TN

- **True Positive (TP):** Betrug wurde erkannt
- **True Negatives (TN):** Reguläre Transaktion wurde erkannt

Aus der Confusion Matrix können verschiedene Metriken berechnet werden:

Precision

$$\frac{TP}{TP + FP}$$

- Precision gibt an, wie viele der als positiv klassifizierten Instanzen tatsächlich positiv sind.

- Hohe Precision bedeutet wenige False Positives.

Recall

$$\frac{TP}{TP + FN}$$

- Recall gibt an, wie viele der tatsächlichen positiven Instanzen korrekt erkannt wurden.
- Hoher Recall bedeutet wenige False Negatives.

F1-Score

$$2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- Der F1-Score ist das harmonische Mittel von Precision und Recall und bietet eine ausgewogene Bewertung der Modellleistung, insbesondere bei unausgewogenen Klassen.
- Eine Verallgemeinerung des F1-Scores ist der F_β -Score, der es ermöglicht, Precision und Recall unterschiedlich zu gewichten.

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precision}) + \text{Recall}}$$

Die Accuracy lässt sich ebenfalls aus der Confusion Matrix berechnen:

$$\frac{TP + TN}{TN + FN + TP + FP}$$

- Die den hier genannten Metriken sind die am häufigsten verwendeten in der Praxis.
- Es gibt jedoch zahlreiche weitere Metriken, z.B. ROC-AUC, Log-Loss, Matthews-Korrelationskoeffizient, etc., die je nach Anwendungsfall sinnvoll sein können.


Übung (3–5 Min.)

Berechnen Sie Precision, Recall, F1-Score und Accuracy für das folgende Beispiel:

		Predicted Class	
		Spam	Non-Spam
Actual Class	Spam	TP=45	FN=20
	Non-Spam	FP=5	TN=30

Regression

Mittlerer absoluter Fehler (Mean Absolute Error, MAE)




$$\text{MAE} := \frac{1}{n} \cdot (|\hat{y}_1 - y_1| + |\hat{y}_2 - y_2| + \dots + |\hat{y}_n - y_n|).$$

- n ist die Anzahl an Daten in der Trainingsmenge
- $y_1, y_2, \dots, y_n$ sind die Werte der Zielvariable
- $\hat{y}_1, \dots, \hat{y}_n$ sind die zugehörigen Vorhersagewerte

Der MAE hat folgende Eigenschaften:

- nie negativ, da Summe von Absolutbeträgen
- ist klein (nahe bei Null), wenn Vorhersagewerte nah bei den wahren Werten liegen
- Alle Abweichungen tragen gleich stark zum Gesamtfehler bei (linear); entsprechend nicht sensibel gegenüber starken Ausreißern
- intuitive Metrik, da in den gleichen Einheiten wie die Zielvariable

Mittlerer quadratischer Fehler (Mean Squared Error, MSE)



$$\text{MSE} := \frac{1}{n} \cdot ((\hat{y}_1 - y_1)^2 + (\hat{y}_2 - y_2)^2 + \dots + (\hat{y}_n - y_n)^2)$$

- Ebenfalls nie negativ, da Summe von Quadraten
- Ist klein (nahe bei Null), wenn Vorhersagewerte nah bei wahren Werten
- gewichtet große Abweichungen stärker durch das Quadrieren
- Da Fehler quadriert werden, kann man MSE nicht mit MAE vergleichen. Vor allem geeignet, um verschiedene Modelle miteinander zu vergleichen.
- Root Mean Squared Error (RMSE, Wurzel aus MSE) von der Größenordnung mit MAE vergleichbar

R^2 (Bestimmtheitsmaß)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- R^2 gibt an, wie gut die Varianz der Zielvariable durch das Modell erklärt wird.
- Werte liegen üblicherweise zwischen 0 und 1, wobei 1 eine perfekte Vorhersage bedeutet. Ein negativer Wert ist möglich und bedeutet, dass das Modell schlechter ist als ein einfaches Mittelwertmodell.
- R^2 ist nützlich, um die Güte eines Regressionsmodells zu bewerten, insbesondere im Vergleich zu einem Nullmodell.

Aufgaben

Aufgabe 1 — Confusion Matrix

Ein binärer Klassifikator wurde anhand von 1000 Testbeispielen evaluiert, in denen 50 % aller Beispiele negativ sind. Es wurde festgestellt, dass der Klassifikator einen Recall von 60 % und eine Genauigkeit von 70 % aufweist. Erstellen Sie die zugehörige Confusion Matrix. Berechnen Sie anschließend die Precision und den F1-Score des

Klassifikators.

Aufgabe 2 — Cut Off Werte

Beim Training eines probabilistischen Klassifikators werden Wahrscheinlichkeiten für die Zugehörigkeit zu den jeweiligen Klassen berechnet. Ein Datenpunkt wird üblicherweise der Klasse mit der höchsten Wahrscheinlichkeit zugeordnet. Eine Erweiterung wäre, einen sog. Cut-Off Wert festzulegen, welchen die Wahrscheinlichkeit zusätzlich überschreiten muss.

Die untere Tabelle zeigt die Wahrscheinlichkeiten für 8 Testdaten sowie die wahre Klasse. Für eine Zuweisung zu den Klassen 1 und 0 gilt folgende Regel: Ist die Wahrscheinlichkeit gleich oder größer als ein vorgegebener Cut-Off-Wert, ordne Klasse 1 voraus, andernfalls Klasse 0.

Berechnen Sie für die Cut-Off-Werte 0.8, 0.7 und 0.3 jeweils die Genauigkeit, Precision und den Recall des Klassifikators. (Sie dürfen die Aufgabe gerne mit einem kleinen Programm lösen.)

example	true class	probability
x1	1	0.94
x2	1	0.75
x3	0	0.63
x4	0	0.56
x5	0	0.44
x6	1	0.25
x7	0	0.19
x8	0	0.13

Aufgabe 3 — Implementierung

Berechnen Sie mit Hilfe der scikit-learn Library die Confusion Matrix sowie den sog. Classification Report, welcher Precision, Recall und F1-Score enthält, für eines der bereits von Ihnen trainierten Klassifikationsmodelle.