

Regularisierung linearer Modelle

Contents

- Regularisierung
- Standardisierung
- Aufgaben

Lernziele

- Den Effekt von Regularisierung auf Modellkomplexität und Generalisierung verstehen und erläutern können
- Zentrale Regularisierungsverfahren für Lineare und Logistische Regression beschreiben und hinsichtlich ihrer Wirkungsweise unterscheiden können
- Die Notwendigkeit der Varianz-basierten Standardisierung mittels z-Score im Zusammenhang mit Regularisierung nachvollziehen und begründen können

Zur Erinnerung

- Lineare Modelle lernen die Gewichte (und den Bias) der linearen Gleichung:

$$\hat{y} = w_0X_0 + w_1X_1 + \dots + w_pX_p + b$$

- Die Vorhersage $h(x)$ für einen Datenpunkt x entspricht dann:

- für Regression: $h(X) = \hat{y}$
- für Klassifikation: $h(X) = \text{sigmoid}(\hat{y})$ bzw. $h(X) = \text{softmax}(\hat{y})$

Loss Function

- Regression: **Mean Squared Error (MSE)**

$$\frac{1}{n} \cdot ((\hat{y}_1 - y_1)^2 + (\hat{y}_2 - y_2)^2 + \dots + (\hat{y}_n - y_n)^2)$$

- Klassifikation: **Cross Entropy Loss**

$$l(\hat{y}, y) = -y \cdot \log(\hat{y}) - (1 - y) \cdot \log(1 - \hat{y})$$

Ein Problem dieser linearen Modelle bei **vielen Features**: sie tendieren zu **Overfitting**, aber es sind keine Hyperparameter vorhanden, um dagegen zu steuern.

Regularisierung

- Verfahren, die ein Modell einschränken, sodass es **weniger over-fitted** ist
- **Reduzieren die Variance**

Die üblichen Regularisierungsverfahren für lineare Modelle basieren auf folgendem Ansatz:

- Gewichte werden so klein 'wie möglich'
- Bedeutet: jedes Feature hat so wenig Einfluss auf die Vorhersage wie möglich
- Umsetzung: Erweiterung der Loss Function durch einen Term, der große Gewichte bestraft

Ridge

Bestraft große Gewichte über die sog. L2-Norm:

$$\|w\|_2^2 = (w_0^2 + w_1^2 + \dots + w_p^2)$$

Ridge Loss

Regression: Finde $w = (w_0, \dots, w_p)$ so dass $\text{MSE} + \alpha \|w\|_2$ minimal wird:

$$\operatorname{argmin}_w \frac{1}{n} ((\hat{y}_1 - y_1)^2 + \dots + (\hat{y}_n - y_n)^2) + \alpha (w_0^2 + w_1^2 + \dots + w_p^2)$$

Klassifikation: Finde $w = (w_0, \dots, w_p)$ so dass $\text{Cross Entropy Loss} + \alpha \|w\|_2$ minimal wird.

Hierbei ist α ein **Hyperparameter**, ähnlich wie das k in k -NN.

Lasso

- Regularisierung durch L1-Norm:

$$\|w\|_1 = |w_0| + |w_1| + \dots + |w_p|$$

Lasso Loss

Regression: Finde $w = (w_0, \dots, w_p)$ so dass $\text{MSE} + \alpha \|w\|_1$ minimal wird:

$$\operatorname{argmin}_w \frac{1}{n} ((\hat{y}_1 - y_1)^2 + \dots + (\hat{y}_n - y_n)^2) + \alpha(|w_0| + |w_1| + \dots + |w_p|)$$

Klassifikation: Finde $w = (w_0, \dots, w_p)$ so dass Cross Entropy Loss + $\alpha \|w\|_1$ minimal wird.

- Effekt: je nach Wahl von α können Gewichte auch ganz verschwinden ($w_i = 0$ für manche i)
- Wirkt wie automatische Feature Selektion und führt zu verständlicheren Modellen, da weniger Features verwendet werden

ElasticNet

- Kombiniert L1 und L2 Norm
- Zusätzlicher Hyperparameter `l1_ratio` regelt das Verhältnis der beiden

Regression: Finde $w = (w_0, \dots, w_p)$ so dass

$$\frac{1}{2n} \cdot \|y - Xw\|_2^2 + \alpha \cdot \text{l1_ratio} \cdot \|w\|_1 + 0.5 \cdot \alpha \cdot (1 - \text{l1_ratio}) \cdot \|w\|_2^2$$

minimal wird.

Klassifikation: analog

Standardisierung

- Wir versuchen Overfitting (Überanpassung) zu reduzieren, indem der Einfluss einzelner Merkmale verringert wird
- Dies geschieht über eine Limitierung der **Größe** einzelner Gewichte

- Allerdings hängt die Größe eines Gewichts w_i vom Wertebereich des zugehörigen Features X_i ab (z.B. Schnabellänge in cm vs Gewicht in Gramm im Palmer Penguins Datensatz)
- Im Kontext von k -NN haben wir dies durch min-max-Scaling als Standardisierungstechnik korrigiert. Effekt: alle Werte zwischen 0 und 1
- Die Gewichte in einem linearen Modell hängen jedoch auch von der **Varianz** des Features ab.
- Der Einfluss eines Features X_i auf die Vorhersage des Modells ist proportional zu

$$w_i \cdot \sigma(X_i)$$

wobei $\sigma(X_i)$ die Standardabweichung der Werte von X_i ist. Denn: Eine typische Streuung im Datensatz ist innerhalb einer Standardabweichung

- Das bedeutet: hat ein Feature X_i hohe Varianz, produziert sogar ein kleines Gewicht w_i eine große Fluktuation in den Vorhersagen, während ein Feature mit geringer Varianz ein deutlich größeres Gewicht für den gleichen Effekt benötigt.

Wir verdeutlichen das an einem Beispiel:

- Angenommen, wir haben zwei Features, X_1 und X_2 .
- Beide haben Werte zwischen 0 und 1
- Aber $\sigma(X_1) = 0.3$ und $\sigma(X_2) = 0.01$. D.h., die Werte von X_2 sind viel stärker beieinander gruppiert.
- Um eine Veränderung der Vorhersage von 0.1 zu erzielen, benötigen wir folgende Gewichte:

$$\begin{aligned} w_1 \cdot 0.3 &= 0.1 \implies w_1 = 0.1/0.3 \sim 0.33 \\ w_2 \cdot 0.01 &= 0.1 \implies w_2 = 0.1/0.01 \sim 10 \end{aligned}$$

- Obwohl also beide Features zwischen 0 und 1 liegen, würde durch Regularisierung der Einfluss von X_2 als ein *low-*

variance Feature deutlich stärker reguliert werden

- Eine Lösung ist das sog. **z-Scoring** oder auch **Mean-Variance Scaling**
- Jedes Feature wird um den Wert 0 zentriert und die Standardabweichung auf 1 genormt:

$$X'_i = \frac{X_i - \text{mean}(X_i)}{\text{std}(X_i)}$$

- Wendet man anschließend Regularisierung an, so verkleinern sich die Gewichte basierend auf der prädiktiven Relevanz der Merkmale, nicht auf willkürlichen Maßstabsunterschieden.
- In `scikit-learn` ist dies in der Klasse `StandardScaler` implementiert

Aufgaben

Aufgabe 1 - Cross validation mit Ridge und Lasso

Führen Sie eine Cross Validation der linearen Regression oder der logistischen Regression und berücksichtigen Sie dabei die drei Regularisierungsverfahren (Ridge, lasso und Elastic Net). Vergleichen Sie die Scores auf der Trainings- und Validierungsmenge. Führen Sie anschließend die Cross Validation auf z-score standardisierten Daten durch. Was fällt Ihnen auf?

Aufgabe 2 - Warum führt L1-Regularisierung zu Feature Selection?

Betrachten Sie ein Regressionsproblem mit zwei Koeffizienten w_1 und w_2 . Angenommen, die Loss Function MSE hat ihr Minimum bei $w_1 = 3, w_2 = 2$.

1. Betrachten Sie den 2-dimensionalen raum der Parameter w_1 und w_2 . Die Loss Function hat einen konstanten

- Wert auf Ellipsen um den optimalen Gewichte-Punkt $(3, 2)$. Zeichnen Sie um den Punkt $(3, 2)$ herum 3–4 Ellipsen mit derselben Grundform. Das genaue Breite/Höhe-Verhältnis ist egal, sollte aber konstant bleiben.
2. Die Ridge-Regularisierung verwendet die L-2-Norm, d.h. dadurch wird dem Ausdruck $w_1^2 + w_2^2$ eine obere Grenze gesetzt. Die Ungleichung $w_1^2 + w_2^2 \leq t^2$ entspricht geometrisch einem Kreis. Zeichnen Sie in die bestehende Zeichnung einen Kreis für einen Radius t Ihrer Wahl.
 3. Zeichnen Sie nun die L1-Beschränkung (Lasso) $|w_1| + |w_2| \leq t$ ebenfalls ein. Geometrisch ergibt dies eine Raute mit Spitzen auf der Achse.
 4. Verkleinern Sie den Wert t , bis die jeweilige Beschränkungsregion die innerste Ellipse gerade berührt. Markieren Sie jeweils den Berührungspunkt.

Welcher Regularisierer (L1 oder L2) berührt eine Ellipse häufiger an einem Punkt, an dem mindestens ein Koeffizient genau 0 ist (also auf den Achsen)? Erklären Sie in 2–3 Sätzen, warum dies zur Merkmalsselektion führt.