

Überwachtes Lernen

Contents

- Wichtige Begriffe und Konzepte
- Beispiel: Leckere Papayas identifizieren
- Input des Lern-Algorithmus
- Output des Lern-Algorithmus
- Loss & Loss Minimization
- Daten
- Aufgaben

Lernziele

- Grundlegende Konzepte und Begriffe des überwachten Lernens (Supervised Learning, SL) kennenlernen
- Ein SL-Problem mathematisch formulieren können
- Mathematisches und praktisches Verständnis von Fehlerminimierung (Loss Minimization) erarbeiten



Wichtige Begriffe und Konzepte


- Überwachtes Lernen = Supervised Learning (SL)

- Automatisierung von Entscheidungsprozessen durch Lernen aus bekannten Beispielen
- Die Daten bestehen aus einer **Output-Variable** und einer oder mehreren **Input-Variablen**, die die Zielvariable beeinflussen.
 - Beispiel: Vorhersage von Mietpreisen. Output: Preis; Input: Fläche, Alter/Baujahr, Deckenhöhe, Altbau ja/nein
 - Input-Variablen heißen auch **Prädiktoren, Merkmale, unabhängige Variablen**
 - Output-Variable heißt auch **Zielvariable, abhängige Variable**.
- SL-Algorithmen werden anhand von **gelabelten** oder **annotierten** Daten **trainiert**, d. h. für jeden Datensatz ist der Wert der Ausgangsvariable bekannt.
- Das trainierte Modell ist in der Lage, einen Wert für die Zielvariable **für ungesehene Daten zu prognostizieren**.
- Wenn "alles gut gelaufen" ist, macht der Algorithmus bei ungesehenen Daten nur "kleine Fehler".
- SL-Algorithmen sind gut verstanden. Wenn das zu lösende Problem als SL formuliert werden kann und wir genügend viele gute Daten haben, ist es sehr wahrscheinlich, dass wir einen effektiven SL-Algorithmus trainieren können

Klassifikation & Regression

- Eine SL-Aufgabe lässt sich als Klassifikation oder als Regression formulieren
- Klassifikation: Vorhersage einer Kategorie
- Regression: Vorhersage einer metrischen Variable
- Es gibt auch Zwischenformen: Ordinale Regression/Klassifikation; eine Art Ranking-Problem





Beispiel: Leckere Papayas identifizieren

- Ich bin auf eine Pazifikinsel gezogen. Dort scheinen Papayas ein wichtiger Bestandteil der Ernährung zu sein.
- Wie erkenne ich, welche gut schmecken?
- Welche Aspekte sollte ich berücksichtigen? Basierend auf bisheriger Erfahrung mit Früchten scheinen Farbe und Festigkeit besonders relevant.
- Farbe: von dunkelgrün über orange und rot bis hin zu braun;
Festigkeit: von steinhart bis hin zu matschig.
- Ich besorge mir eine (zufällige) Auswahl von Papayas, probiere sie und notiere, welche gut/schlecht geschmeckt hat.



Input des Lern-Algorithmus

1. Urbildmenge (Domain Set):

Mathematische Darstellung von Objekten, die wir klassifizieren wollen. Wird üblicherweise mit X bezeichnet. Jeder Datenpunkt wird als sog. **Feature-Vektor** dargestellt.

$$x_1 \begin{pmatrix} 0.1 \\ -0.6 \end{pmatrix}, x_2 \begin{pmatrix} -0.3 \\ 0.56 \end{pmatrix}, \dots, x_n = \begin{pmatrix} [Farbe] \\ [Festigkeit] \end{pmatrix}$$

2. Bildmenge (Zielmenge, Label Set):

Klassen oder Labels, üblicherweise repräsentiert als $\{0, 1\}$ oder andere Zahlen, v.a. bei mehr als 2 Klassen. Wird

typischerweise mit Y notiert.

3. Trainingsdaten (Training Data):

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \in X \times Y$$

Achtung: $x_1, x_2, \dots$ sind **n -dim Vektoren** (n ist Anzahl an Features).

4. Algorithmen (Verfahren, Hypothesen-Raum)

Klasse von Funktionen, aus welcher die Vorhersage-Funktion h , die beim Training gelernt werden soll, ausgewählt werden kann (z.B. lineare Funktionen).

- Modelle für maschinelles Lernen sind typischerweise Implementierungen mathematischer Funktionen
- $\rightarrow$ die ML-Aufgabe muss mathematisch formuliert werden, und die Daten müssen passende mathematische Objekte sein

Output des Lern-Algorithmus

Vorhersage-Funktion / Vorhersage-Modell / Prädiktor

$$h : X \rightarrow Y.$$

Papaya-Beispiel: Prädiktor soll für neue Papayas vorhersagen, ob sie gut oder schlecht schmecken.

Loss & Loss Minimization

Perfektes Modell

Nehmen wir an, dass es ein **perfektes Modell** gibt

$$f : X \rightarrow Y,$$

das immer korrekte Vorhersagen macht, das wir aber nicht kennen. Die Ausgabe des Lernalgorithmus ist also eine **Annäherung an das perfekte Modell f** .

Fehler (loss, error)

Der **Fehler** des Vorhersagemodells ist definiert als die **Wahrscheinlichkeit, eine falsche Vorhersage für einen zufällig ausgewählten Datenpunkt** (Papaya) zu treffen.

Das heißt, der Fehler entspricht der Wahrscheinlichkeit, dass für einen zufälligen Datenpunkt x gilt

$$h(x) \neq f(x)$$

Synonyme: Generalisierungsfehler (generalization error), true error, risk.

Typische Schreibweise: L ; kommt von "Loss (function)".

Fehlerminimierung

Der Lernalgorithmus soll einen Prädiktor finden

$$h : X \rightarrow Y$$

finden, so dass h den wahren Fehler so weit wie möglich minimiert.

Empirical Risk Minimization (ERM)

Der Lernalgorithmus hat jedoch nur Zugriff auf eine Datenstichprobe S und kennt weder die Verteilung der Daten noch das perfekte Modell f .


Da die Trainingsmenge eine Teilmenge der realen Welt ist und uns diese Menge zur Verfügung steht, erscheint es erstmal sinnvoll, den Fehler in dieser Menge zu minimieren (ERM):

Training-Error (empirisches Risiko)

Anteil der Datenpunkte aus der Trainingsmenge, für die der Prädiktor eine falsche Vorhersage trifft.

Was kann mit ERM schief gehen?

- Angenommen, alle Papayas sind gleichmäßig in der äußeren Box verteilt, d. h. alle Kombinationen von Farbe (horizontal) und Stärke (vertikal) in dem Bereich sind gleich wahrscheinlich.
- Angenommen, Papayas im inneren Quadrat sind lecker und der Rest nicht (Annahme über die perfekte Funktion f). Inneres Quadrat hat Fläche 1, das äußere 2.
- Sei $h: X \rightarrow Y$ so, dass h sich alle Werte aus den Trainingsdaten S merkt und entsprechend richtig vorhersagt, und sonst immer 0 ausgibt, d. h., $h(x_i) = y_i$ wenn $x_i \in S$ und $h(x) = 0$ sonst.
- Wie groß ist der Fehler $L_S(h)$?



Fehler $L_S(h)$ von h :


- ist die Wahrscheinlichkeit, eine Papaya x zufällig so auszuwählen, dass $h(x) \neq f(x)$.
- Wir denken an unendlich viele Papayas, so dass wir die wenigen in der Trainingsmenge ignorieren können.
- $L_S(h)$ ist also ungefähr die Wahrscheinlichkeit, dass ein x so gezogen wird, dass $f(x) \neq 0$ ist, also $f(x) = 1$.
- $f(x) = 1$ im inneren Kasten, dieser hat die halbe Fläche des ganzen Kastens, in dem die Papayas gleichmäßig verteilt sind.
- D.h. die Chance, ein x zufällig zu ziehen, so dass $f(x) = 1$, ist $1/2$.

Dieser Prädiktor:

- ist perfekt im Sinne der ERM: der empirische Fehler kann nicht kleiner sein
- aber er schneidet bei ungesehenen Beispielen sehr schlecht ab (1/2)
- Dieses Phänomen wird als **Überanpassung (Overfitting)** bezeichnet: **das Modell passt sich zu gut an die Trainingsdaten an**, lernt aber wenig über das vorherzusagende Problem.

ERM mit induktivem Bias

- Wir müssen den ERM-Ansatz etwas anpassen, um eine Überanpassung zu verhindern
- D.h. wenn der Prädiktor auf den Trainingsdaten gut performt, soll er dies auch auf den ungesehenen Daten
- Ein wichtiger Schritt bei ML ist die a priori Beschränkung auf eine Klasse von Funktionen, **die Modell-Familie**, aus der h ausgewählt werden kann
- D.h. h kann nicht mehr beliebig (komplex) sein, sondern hat bestimmte spezifizierte Eigenschaften
- Die Eigenschaft, sich "die gesamten Trainingsdaten zu merken", haben v.a. komplexere Funktionen mit vielen Parametern




- Auf diese Weise schaffen wir einen **induktiven Bias** für die ausgewählte Klasse von Funktionen
- Da die Beschränkung auf eine Klasse von Funktionen erfolgt, bevor der Lernalgorithmus die Trainingsdaten sieht, sollte sie durch unser Wissen über die Welt, die wir zu modellieren versuchen, gerechtfertigt sein

- Die geringere Wahrscheinlichkeit für Overfitting geht oft mit geringerem Lernerfolg einher. Es gilt, dieses Kompromiss bestmöglich zu gestalten.

Papaya-Geschmack lässt sich wahrscheinlich gut mit Rechtecken modellieren

(zunächst egal, wie entsprechende Funktionen mathematisch dargestellt werden können...)



Im Kurs lernen wir verschiedene Mechanismen kennen, die zur Erkennung und Reduzierung von Overfitting eingesetzt werden können.

Diskussion (3–5 Min.)


Welche Funktion / welchen Fehler könnte man im Falle einer Regression / Klassifikation minimieren?

► **Regression**

Für Regression wird typischerweise der **Mean Squared Error** gewählt:

$$\frac{1}{n} \cdot (y_1 - \hat{y}_1)^2 + \dots + (y_n - \hat{y}_n)^2,$$

wobei y_i die Werte der Zielvariable der Trainingsdatenpunkte ist und $\hat{y}_i$ die Werte der vorhergesagten Zielvariable.




► Klassifikation

Für Klassifikation würde sich inhaltlich die sog. **Fehlerrate** oder **Ungenauigkeit** (engl. **error rate, inaccuracy**) anbieten. Diese entspricht dem **Anteil falsch klassifizierter Datenpunkte**.

Diese lässt sich, im Gegensatz zum MSE, nicht gut optimieren (dies hat mathematische Gründe wie z.B. Nicht-Differenzierbarkeit); deshalb wird eine Ersatzfunktion verwendet, die sog. **Cross Entropy Loss**; über sie lernen wir im Semester mehr.

Train-Test-Split

- Wie können wir nun berechnen, wie gut das Modell auf ungesehenen Daten (Papayas, die wir morgen kaufen wollen) performt?
- Wir **schätzen den tatsächlichen Fehler, indem wir die annotierten Daten in eine Trainingsmenge und eine Testmenge aufteilen**, d. h. wir lassen einen Teil der Daten beiseite, auf die der Lernalgorithmus nicht zugreifen kann, und berechnen den Fehler des trainierten Modells auf den Testdaten.



Daten

- Wir sammeln Daten, die (statistisch) denjenigen **ähneln**, auf die das trainierte Modell später angewendet werden soll
- Damit ein Lern-Algorithmus Daten verarbeiten kann, ist üblicherweise eine "geeignete" **numerische Repräsentation der Daten** notwendig (es gibt bessere und schlechtere; dazu mehr im Laufe des Semesters)
- Jeder **Datenpunkt** (Daten-Sample, Daten-Beispiel) besteht aus sog. **Features**, welche relevante Informationen

der Datenpunkte repräsentieren und auf welchen die Vorhersagen des Modells basieren

Diskussion (3–5 Min.)

Diskutieren Sie folgende Aspekte anhand eines Anwendungsfalls Ihrer Wahl (siehe Auswahl unten).

- Handelt es sich um eine Regressions- oder Klassifikationsaufgabe? Im Falle einer Klassifikation: wieviele mögliche Werte hat die Zielvariable (Anzahl Klassen)?
- Wie würden Sie Daten für das Training sammeln?
- Wie würden Sie die Input-Daten numerisch repräsentieren?

Sie können aus den folgenden Anwendungsfällen wählen:

1. Vorhersage, ob auf einem Foto, aufgenommen z.B. mit einer iPhone 7 Kamera, ein Gesicht zu sehen ist
2. Vorhersage, ob in einem Film-Review eine positive oder negative Stimmung vermittelt wird
3. Vorhersage, wann ein*e Patient*in nach der Entlassung aus dem Krankenhaus wieder ins Krankenhaus kommen wird, basierend auf den Daten aus der Gesundheitsakte
4. Vorhersage des nächsten Wortes in HipHop-Lyrics

► Anwendungsfall 1

- Binäre Klassifikationsaufgabe. (Aber es ist möglich, die Aufgabe auch als Regression zu modellieren, indem nur die Wahrscheinlichkeit für Label: "ja" vorhergesagt wird)
- Selbst Fotos aufnehmen; Crowd-Collection; Internet-Quelle suchen (Richtlinien für Nutzung der Daten beachten), ...
- Wir nehmen hier eine feste Auflösung der Fotos an, z.B. 200 x 200 Pixel, da ein Kamera-Typ, und dass es sich um Fotos in Farbe handelt. Dann würden wir jedes Pixel als RGB Code repräsentieren; somit würde jedes Datenbeispiel $200 \cdot 200 \cdot 3 = 120,000$ Features haben.

► Anwendungsfall 3

- Regressionsaufgabe (Zielvariable ist Anzahl an Tagen, nach oben offen)
- Angenommen, wir arbeiten für das Krankenhaus selbst und haben Zugang zu den Akten der Patient*innen, die dort aufgenommen wurden, würden wir diese verwenden. Aus diesen lassen sich nicht nur Angaben über den Gesundheitszustand der Person entnehmen sondern auch, wann sie im Krankenhaus aufgenommen wurden (Werte für die Zielvariable)
- Attribute wie Laborwerte, bestehende Erkrankungen sowie sozio-demographische Angaben beinhalten sicherlich relevante Informationen. Ein Teil davon ist bereits numerisch; Kategorische Attribute müssen über Verfahren wie das sog. One-Hot-Encoding umgewandelt werden.

► Anwendungsfall 4

- Klassifikationsaufgabe; jedes Wort aus dem Vokabular ist eine Klasse; entsprechend hängt die Anzahl von Klassen von der Größe des Vokabulars ab (sehr groß, außer wir reduzieren das geschickt; dazu später im Semester mehr)
- Lyrics aus dem Internet herunterladen
- Für numerische Repräsentation gibt es viele Möglichkeiten. Man kann sog. One-Hot-Encoding durchführen (Angenommen das Vokabular ist alphabetisch sortiert und hat die Größe N . Dann wird jedes Wort repräsentiert als ein Vektor der Länge N bestehend aus einer 1 an der Index-Position des Wortes im Vokabular und sonst aus Nullen). Man kann auch semantische Repräsentationen lernen; dazu später im Semester mehr.

- In diesen Fällen haben die Repräsentationen der Daten eine feste Länge. Dies ist die **Dimension** der Daten bzw. des mathematischen Vektorraums der Input-Daten.
- Nicht alle Daten lassen sich immer gut mit Vektoren fixer Länge repräsentieren. Z.B. stammen nicht alle Bilder aus

der gleichen Quelle (können nicht immer die gleiche Kamera annehmen). Genauso sind Texte oder Video-Sequenzen unterschiedlich lang.

- Reduzieren geht zwar immer, führt jedoch auch zu **Informationsverlust**.
- Ein großer Vorteil einiger Deep Learning Architekturen ist ihre Fähigkeit, Daten-Repräsentationen unterschiedlicher Länge zu handhaben.

Datenquantität und -qualität

- Deep Learning (DL) Modelle benötigen mehr Daten als klassische ML Verfahren. Mehr Daten war der Haupt-Driver für den Erfolg von DL Modellen
- Die Datenqualität ist wichtig: Fehler in Daten minimal halten, statistisch repräsentativ, etc. Dies hat nicht nur Einfluss auf Performance der Vorhersage (die kann ja gut sein auf Testdaten), sondern auch negative Konsequenzen hinsichtlich potenzieller Diskriminierung und Benachteiligung (z.B. Vorhersage von Hautkrebs aber Trainingsdaten hatten kaum Samples von nicht-weißen Personen). Anm.: Diskriminierung durch ML Modelle lässt sich nicht (nur) technisch lösen; es gibt weitaus mehr Probleme als unausgewogene Trainingsdaten.

Viele dieser Konzepte gelten auch für andere Formen des ML, nicht nur für SL

Lern-Algorithmus (Lösung der Fehler-Minimierungsaufgabe)

- Mit den bisherigen Schritten haben wir Input/Output mathematisch definiert; eine Modell-Familie ausgewählt; Fehlerfunktion spezifiziert; und Daten gesammelt. Es fehlt der Algorithmus, um "das optimale Modell" in der Modell-Familie zu finden.
- ML-Modelle kommen mit eigenen Lernalgorithmen, die wir in den nächsten Wochen für ausgewählte Beispiele kennenlernen werden.
- Bei DL Modell-Familien werden Algorithmen basierend auf dem sog. **Gradientenabstieg** (engl. **gradient descent**)

verwendet. Grob gesagt, prüft dieses Verfahren in jedem Schritt, in welche Richtung die Parameter verändert werden müssen, damit die Loss auf den Trainingsdaten so viel wie möglich reduziert wird.

- Hierfür müssen wir sog. **Richtungsableitungen** berechnen.
- Im Rahmen dieser LV werden wir auf dieses Thema nicht eingehen können (Wahlpflicht Deep Learning).

Aufgaben


Aufgabe 1 - Begriffe

Welche der folgenden Aussagen ist korrekt?

1. Trainingsdaten werden verwendet, um ein überwachtes maschinelles Lernmodell zu trainieren.
2. Ein Modell ist eine spezifische Instanz einer Modell-Familie.
3. Ein Lernalgorithmus wird verwendet, um das optimale Modell einer Modell-Familie zu finden
4. Überwachtes Lernen ist eine Form des maschinellen Lernens, bei der das Modell aus gelabelten Daten lernt.
5. Eine Überanpassung/Overfitting liegt vor, wenn ein Modell zu einfach ist und die Komplexität der Daten nicht erfassen kann.
6. Ein Feature ist eine messbare Eigenschaft oder Charakteristik der Daten.
7. Die Testdaten werden zum Trainieren eines maschinellen Lernmodells verwendet.

Aufgabe 2 - Wahl der Fehlermetrik

In der Vorlesung haben wir den Mean Squared Error (MSE) als die übliche loss function für Regression kennengelernt. Angenommen Sie wollen die optimale lineare Funktion zu dem Datensatz in der folgenden Abbildung bzgl. MSE finden.



1. Wie könnte diese in etwa aussehen, wenn Sie die Ausreisser/Outlier unten rechts ignorieren? Zeichnen Sie Ihre Lösung ein.
2. Was ändert sich, wenn Sie die Ausreisser mit berücksichtigen?
3. Wie könnten Sie die Formel des MSE anpassen, um diesem Effekt etwas entgegen zu wirken?