

Kurzbericht RAG (Retrieval-Augmented Generation) für eigene (Data Science) Lernunterlagen

1. Thema & Datenbeschreibung

Im Praxisprojekt habe ich einen funktionsfähigen Retrieval-Augmented-Generation Systems (RAG) entwickelt, das Antworten auf eigene Studien-Lernunterlagen (im PDF-Format), wie Kursfolien und eigenen Notizen liefert. Konkrete prüfungsbezogene Fragen können basierend auf dem Datensatz beantwortet werden. Bei den Antworten werden die Quellen und Seitenzahlen mit angegeben sodass die Student:innen überprüfen können, ob die Antworten korrekt sind. Die Halluzination des RAGs werden reduziert und die Antworten beziehen sich direkt auf die Quellen. Dieser RAG ist für den spezifischen Anwendungsfall mit kursbezogenen Data-Science-Dokumenten und eigenen Prüfungsvorbereitungs-Notizen entwickelt und soll dazu dienen, Wissen zu wiederholen und zu festigen. Ich habe mich bewusst dazu entschieden dass Grafiken in diesem RAG nicht behandelt werden und den Fokus auf die textbezogene Verarbeitung zu legen. Bei bildbezogenen Fragen antwortet das Modell daher, dass es dies nicht weiß. Es können teilweise Fragen zu mathematischen Formeln beantwortet werden, mit teilweise entsprechenden mathematischen Zeichen. Z.B. bei einer Frage nach dem MSE (Mean Squared Error) wird die richtige Formel ausgegeben. Für Fragen zu mathematischen Formeln ist dieses Modell allerdings nicht konzipiert. In einer Erweiterung könnte dies noch umgesetzt werden. Der Schwerpunkt liegt beim RAG vor allem auf der Beantwortung von inhaltlichen konzeptionellen Fragen wie, z.B. wie ich die optimalen Hyperparameter finden kann. Als Datengrundlage habe ich Jupyter Notebooks aus dem Kurs Data Science von Prof. Mihaljevic in PDFs formatiert. Aufgrund der Formatierungen sind die PDFs stark verrauscht und beinhalten Bilder, viele Leerstellen, Sonderzeichen und Metadaten. Hinzugenommen habe ich zudem eigene Lernnotizen, die ebenfalls verrauscht sind. Die Daten bilden daher eine Herausforderung darauf aufbauend einen funktionalen RAG zu entwickeln.

2. Systemarchitektur (Daten → Retrieval → LLM)

2.1 Preprocessing & Embeddings:

Der RAG besteht aus drei Hauptkomponenten: Daten, Retrieval und LLM. Im Preprocessing werden zunächst PDFs mit PyPDFDirectoryLoader geladen und mit der Funktion `clean_text` bereinigt. Die Seitenzahlen werden von 0-basiert auf 1-basiert korrigiert, damit die Seitenzahlen korrekt angegeben werden können. Die Dokumente werden anschließend in Chunks (Chunksize: 1000, Overlap 200) gesplittet. Mit dem Embedding-Modell `sentence-transformers/paraphrase-multilingual-mpnet-base-v2` von HuggingFace werden semantische Vektoren erzeugt. Die Chunks werden in der Vektordatenbank Chroma gespeichert.

2.2 Retrieval:

Beim Retrieval werden Dokumentchunks basierend auf vektorbasierter Suche mit semantischer Ähnlichkeit zwischen der Frage und dem Dokumentchunk herausgefiltert. Die Top-k Treffer werden inklusive der Quelle und Seitenzahl zurückgegeben. Das k ist auf 5 konfiguriert, also die ersten 5 Treffer werden der User:in angezeigt.

2.3 Generierung

In einem Streamlit-Frontend können Fragen und Antworten zu den Lernmaterialien gestellt werden. Für die Antwortgenerierung habe ich ein lokales Modell von Ollama gemma2:2b eingebunden. Der System-Prompt zwingt das Modell, nur den Kontext zu verwenden und antwortet bei fehlender Antwort „Ich weiß es nicht“. Es werden dann aber trotzdem Quellen angegeben, die bei der Beantwortung der Frage passend sein könnten. Durch den System-Prompt werden nicht anwendungsbezogene Fragen wie z.B. „Wie ist das Wetter“ mit „Ich weiß es nicht“ beantwortet, damit der Fokus bei den Lernmaterialien bleibt und Halluzinationen verringert werden.

3. Evaluation (Metriken & manuelle Bewertung)

3.1 Manuelle Bewertung:

Das System wurde auf zwei Ebenen bewertet. Dabei habe ich in mehreren Sprints iterativ die Anwendung entwickelt, anhand einiger Beispielfragen evaluiert, anschließend Fehler behoben und erneut getestet. Ein Teil der Zwischenergebnisse der manuellen Evaluation ist in der Dokumentation.txt Datei festgehalten. Bei der manuellen Bewertung habe ich die Antworten nach Relevanz, Faktentreue und Groundedness bewertet. Die Groundedness ist wie folgt bewertet:

Bei vollständiger Antwort (1), bei teilweise korrekter Antwort (0.5), bei gar keiner Antwort oder Halluzination (0). Die Relevanz beschreibt wie relevant die Dokumente für die Query sind und habe ich in einer Skala von 1 bis 5 bewertet. Die Faktentreue beschreibt wie hilfreich und faktentreu die generierte Antwort ist und ob die gefundenen Dokumente korrekt verwendet werden und ist ebenfalls in einer Skala von 1 bis 5.

3.2 Automatisierte Bewertung:

Für die automatisierte Evaluation habe ich das Retrieval mit Precision@k, Recall@k bewertet. Die Precision@k beschreibt den Anteil relevanter Dokumente unter den Top-k Treffern. Der Recall@k steht für den Anteil der gefundenen relevanten Quellen im Verhältnis zu allen relevanten Quellen. Für das k habe ich 5 gewählt. Die Antwortqualität habe ich mit Cosine Similarity bewertet. Cosine Similarity misst die semantische Ähnlichkeit der Antworten auf Basis der Embeddings. Sie ist ein Indikator dafür, wie ähnlich sich die Antworten inhaltlich sind, stellt jedoch keinen direkten Beweis für die faktische Korrektheit dar. Daher ist auch eine manuelle Überprüfung wichtig.

3.2 Beispielfragen:

Die finale manuelle und automatisierte Evaluation basiert auf folgenden 7 Beispielfragen:

Beispielfrage 1: Was ist ein Hyperparameter?

EA (Erwartete Antwort): Das sind die Parameter die vor dem eigentlichen Training festgelegt werden.
(DS Pruefungsvorbereitung, Seite 14)

Beispielfrage 2: Wie kann ich den Einfluss von Hyperparametern messen?

EA: "Das Modell mit verschiedenen Hyperparametern trainieren und die Performance auf den Validierungsdaten vergleichen" (DS Pruefungsvorbereitung, Seite 14)

Beispielfrage 3: Wie kann ich die optimalen Hyperparameter-Werte finden?

EA: "durch die Cross Validation, Grid Search"(DS Pruefungsvorbereitung, Seite 14)

Beispielfrage 4: Was ist Overfitting?

EA: Überanpassung: Modell zu komplex (DS Pruefungsvorbereitung, Seite 17)

Beispielfrage 5: „Wofür wird Machine Learning verwendet?“

EA: „Seit einigen Jahren ist Machine Learning (ML) zu einem Standardwerkzeug für fast alle Aufgaben geworden, bei denen Informationen aus Daten extrahiert werden müssen“ (Einführung in Maschinelles Lernen, Seite 1)

Beispielfrage 6: „Was ist ein Domain Set?“

EA: „Urbildmenge“ (Überwachtes Lernen, Seite 5)

Beispielfrage 7: „Wo kommt die IQR Regel her?“

EA: „von John Tukey“ (Data Preprocessing, Seite 6)

Die finale Bewertung zu 7 Beispielfragen ist in der Tabelle (siehe unten) zu finden. Die Tabelle bietet eine Übersicht pro Frage über die erwartete Antwort, tatsächliche Antwort, Groundedness, Relevanz, Faktentreue, Precision@k, Recall@k und Cosine Similarity.

Frage	Erwartete Antwort:	Antwort	Groundedness	Relevanz (1-5)	Faktentreue (1-5)	Precision@5	Recall@5	Cosine Similarity
1	„Das sind die Parameter die vor dem eigentlichen Training festgelegt werden.“	Hyperparameter sind die Parameter, die vor dem eigentlichen Training festgelegt werden.	1	4	4	0.20	1.00	0.76

2	„Das Modell mit verschiedenen Hyperparametern trainieren und die Performance auf den Validierungsdaten vergleichen“	Um den Einfluss von Hyperparametern zu messen, trainieren Sie das Modell mit verschiedenen Hyperparametern und vergleichen Sie die Performance auf den Validierungsdaten.	1	4	4	0.40	1.00	0.92
3	„durch die Cross Validation, Grid Search“	Durch die Cross-Validation und Grid Search.	1	4	4	0.20	1.00	0.91
4	„Überanpassung: Modell zu komplex“	Overfitting ist ein Phänomen, bei dem ein Modell sich zu gut an die Trainingsdaten anpasst und wenig über das zu vorherzusagende Problem lernt.	1	3	4	0.40	1.00	0.47
5	„Seit einigen Jahren ist Machine Learning (ML) zu einem Standardwerkzeug für fast alle Aufgaben geworden, bei denen Informationen aus Daten extrahiert werden müssen“	Machine Learning wird verwendet, um Informationen aus Daten zu extrahieren.	1	3	3	0.00	0.00	0.85
6	„Urbildmenge“	Ein Domain Set ist die mathematische Darstellung von Objekten, die wir klassifizieren wollen.	1	2	2	0.00	0.00	0.27
7	„von John Tukey“	Die IQR Regel stammt von John Tukey.	1	2	3	0.20	1.00	0.67

Die durchschnittliche Precision@5 liegt bei: 0.200

Die durchschnittliche Recall@5 liegt bei: 0.714

Die durchschnittliche Cosine Similarity liegt bei: 0.692

Der Recall@5 liegt im Durchschnitt bei 0.714 und die Precision@5 liegt im Schnitt nur bei: 0.200. Der Recall@k zeigt dass die relevanten Dokumente in den meisten Fällen unter den Top-k Treffern liegen. Das bedeutet, dass das Retrieval in der Lage ist, relevante Quellen grundsätzlich zu identifizieren. Allerdings nicht immer, wie sich in Frage 5 und 6 zeigt, wo der Recall@5 bei 0.00 liegt. Bei der manuellen Überprüfung bei Frage 5 und 6 habe ich bei der Relevanz eine 2 von 5 vergeben, da ein paar Dokumente einigermaßen passend waren. Im Vergleich zu den anderen Fragen sind es aber deutlich weniger relevante Dokumente. Die relevanten Dokumente waren zudem öfters nicht der erste Treffer, was die Precision@5 beeinflusst hat. Die niedrige Precision@5 zeigt, dass sich unter den Top-5 Treffern häufig auch viele nicht relevante Dokumente befinden. Das Retrieval ist somit eher unscharf.

Die Cosine Similarity von durchschnittlich 0.692 deutet darauf hin, dass die generierten Antworten semantisch häufig nahe an den erwarteten Antworten liegen. Dennoch kann diese Metrik nicht zwischen vollständig korrekten und nur teilweise richtigen Antworten unterscheiden. Daher ist auch hier die manuelle Evaluation wichtig.

Bei der manuellen Evaluation habe ich alle 7 Antworten mit Groundedness 1 bewertet, da die Antworten im wesentlichen korrekt waren und die passenden Quellen mit Seitenzahlen unter den Treffern gefunden wurden. Da das Modell bei den gestellten Fragen kaum halluziniert aber nicht die perfekten Antworten zurückgibt ist die Faktentreue im Durchschnitt 3.42.

Trotz niedriger Precision@k kann das Modell häufig korrekt antworten, da relevante Informationen meist in den Top-k Treffern enthalten sind (hoher Recall@k). Die relevanten Dokumente werden meist innerhalb der Top-k Treffer gefunden, jedoch nicht immer auf den ersten Positionen. Die niedrige Precision@5 zeigt, dass sich unter den Top-5 Treffern insgesamt viele nicht relevante Dokumente befinden. Die Ergebnisse zeigen insgesamt, dass das System relevante Informationen meist erfolgreich abrufen, diese jedoch nicht immer optimal priorisiert werden. Insgesamt zeigt sich, dass die Hauptschwäche des Systems im Retrieval liegt (insbesondere in der Präzision der Treffer). Dies liegt vor allem an der Qualität der Datenbasis und kann mit weiterer Vorverarbeitung wie z.B. Textbereinigung behoben werden.

4. Reflexion (Erkenntnisse, Probleme, Ausblick)

4.1 Erkenntnisse:

Zu Anfang hatte ich verschiedene PDFs getestet und festgestellt, dass die Qualität und Formatierung der PDFs einen starken Einfluss auf die Retrieval-Performance haben. Durch Vorverarbeitungsschritte, wie z.B. das rausfiltern von Leerstellen konnte die Leistung verbessert werden. Anfangs hatte ich u.a. noch BERT verwendet und konnte durch den Wechsel des Embedding-Models paraphrase-multilingual-mpnet-base-v2 die Performance deutlich verbessern. Für eine gute Performance ist die Qualität der Datengrundlage, die Bereinigung, das Chunking und das semantische Retrieval entscheidend für die Performance. Wenn ich PDFs verwendet habe, die sauber formatiert waren, stieg die Antwortqualität signifikant an. Auch die Implementation des Systemprompts wodurch Halluzinationen vermieden werden, konnten die Antwortgenauigkeit verbessern. Eine weitere Erkenntnis ist das spezifischere Fragen besser als allgemeine Fragen beantwortet werden können.

4.2 Probleme

Die korrekten Treffer liegen oft nicht an erster Stelle, trotzdem beantwortet das Modell die meisten Beispielfragen korrekt. Die Precision@k bei k=5 ist niedrig und liegt im Schnitt bei 0.200. Das Modell hat teilweise Schwierigkeiten Fragen korrekt zu beantworten. Vor allem bei sehr allgemeinen Fragen, was auch nachvollziehbar ist, wenn bestimmte Begriffe häufig vorkommen und die Frage nicht

spezifisch genug gestellt ist. Da allgemein Fragen zudem weniger spezifische semantische Anker haben, wird das Retrieval unschärfer. Das Finden von konkreten Zitaten oder bei stark formatierten Textstellen bringt außerdem noch Schwierigkeiten mit sich.

4.3 Ausblick

Da die PDF Folien sehr verrauscht sind, können Fragen teilweise nicht korrekt beantwortet werden. Fragen die mithilfe der eigenen Notizen zur Prüfungsvorbereitung gestellt werden, können besser beantwortet werden. Ich habe bewusst Rechtschreibfehler, Grammatikfehler und einige ungünstige Formatierungen und Sonderzeichen in den PDFs belassen um zu prüfen wie sich dies auf die Antwortqualität auswirkt. Im wesentlichen werden korrekte Antworten zurück gegeben, nur die Treffer liegen nicht an erster Stelle. Ein weiteres Bereinigen könnte sich daher positiv auf den Score auswirken. Bei einigen mathematischen Formeln gibt es ebenfalls noch Schwierigkeiten die bei einer Weiterentwicklung behoben werden könnten.

Bei der Text-Bereinigung könnten zudem Metadaten, Datum und Uhrzeit, doppelte Webadressen, Fußnoten, Wiederholungen wie Coursebook etc. entfernt werden. Eine gewichtete Suche wie Whoosh (BM25) könnte irrelevante Treffer reduzieren. Zudem könnten doppelte Treffer entfernt werden. Weitere Stellschrauben wären das Kontext-Fenster und die Chunkgröße. Zudem könnten weitere Testdurchläufe mit weiteren Fragen gemacht werden um die Stabilität der Antwortgenerierung zu testen sowie um zu prüfen wie die Performance des Modells bei weiteren Fragen ist.

Fazit: Der RAG beantwortet die Fragen funktional und in den meisten Fällen korrekt und gibt meistens die richtigen Quellen an und halluziniert kaum. Als nächster Schritt wäre eine gewichtete Suche passend sowie weitere automatisierte Evaluationsmetriken zu testen um die passenden Treffer an die erste Stelle zu bekommen. Optional könnten auch die Antworten etwas Leser:innenfreundlicher gestaltet werden, aber für private Lernzwecke, das Suchen von bestimmten Informationen, Wiederholen von Lerninhalten und Beantworten von kleineren Fragen reicht das RAG bereits aus.

5. Anhang

5.1 Automatisierte Evaluation:

```
Frage 1: Was ist ein Hyperparameter?
Antwort: Hyperparameter sind die Parameter, die vor dem eigentlichen Training festgelegt werden.

Precision@5: 0.20
Recall@5: 1.00
Cosine Similarity: 0.76
-----
Frage 2: Wie kann ich den Einfluss von Hyperparametern messen?
Antwort: Um den Einfluss von Hyperparametern zu messen, trainieren Sie das Modell mit verschiedenen
Hyperparametern und vergleichen Sie die Performance auf den Validierungsdaten.

Precision@5: 0.40
Recall@5: 1.00
Cosine Similarity: 0.92
-----
Frage 3: Wie kann ich die optimalen Hyperparameter-Werte finden?
Antwort: Durch die Cross-Validation und Grid Search.

Precision@5: 0.20
Recall@5: 1.00
Cosine Similarity: 0.91
-----
Frage 4: Was ist Overfitting?
Antwort: Overfitting ist ein Phänomen, bei dem ein Modell sich zu gut an die Trainingsdaten anpasst
und wenig über das zu vorherzusagende Problem lernt.

Precision@5: 0.40
Recall@5: 1.00
Cosine Similarity: 0.47
-----

Frage 5: Wofür wird Machine Learning verwendet?
Antwort: Machine Learning wird verwendet, um Informationen aus Daten zu extrahieren.

Precision@5: 0.00
Recall@5: 0.00
Cosine Similarity: 0.85
-----
Frage 6: Was ist ein Domain Set?
Antwort: Ein Domain Set ist die mathematische Darstellung von Objekten, die wir klassifizieren wollen
.

Precision@5: 0.00
Recall@5: 0.00
Cosine Similarity: 0.27
-----
Frage 7: Wo kommt die IQR Regel her?
Antwort: Die IQR Regel stammt von John Tukey.

Precision@5: 0.20
Recall@5: 1.00
Cosine Similarity: 0.67
-----

Ergebnisse:
Durchschnitt Precision@5: 0.200
Durchschnitt Recall@5: 0.714
Durchschnitt Cosine Similarity: 0.692
```

RAG fürs Lernen

Antwort: Hyperparameter sind die Parameter, die vor dem eigentlichen Training festgelegt werden.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/Hyperparameter.pdf | Seite: 2]

. solche variablen heißen hyperparameter • unser erstes ziel ist zu verstehen, wie wir den einfluss von hyperparametern messen können und wie wir die optimalen hyperparameter werte finden
hyperparameter am beispiel von nn • wie hängt die performance eines nn modells von ab • wir betrachten als beispiel den palmer penguins datensatz k k k k modellkomplexität und modellauswahl — ds course book https://ds.coursebook.pages.dev/modellauswahl_knn 2 von 20
24.01.26, 17:00

[Treffer 2 | Quelle: Data/Modellkomplexität und Modellauswahl.pdf | Seite: 2]

. solche variablen heißen hyperparameter • unser erstes ziel ist zu verstehen, wie wir den einfluss von hyperparametern messen können und wie wir die optimalen hyperparameter werte finden
hyperparameter am beispiel von nn • wie hängt die performance eines nn modells von ab • wir betrachten als beispiel den palmer penguins datensatz k k k k modellkomplexität und modellauswahl — ds course book https://ds.coursebook.pages.dev/modellauswahl_knn 2 von 20
04.04.26, 16:53

[Treffer 3 | Quelle: Data/DS_PruefungsvorbereitungFragenundAntwortenKlein.pdf | Seite: 14]

eigene fragen: 1) was sind hyperparameter a: **das sind die parameter die vor dem eigentlichen training festgelegt werden** bei k nn das k. 2) wie kann ich den einfluss von hyperparametern messen a: das modell mit verschiedneen hyperparametern trainieren und die performance auf den validierungsdaten vergleichen. 3) wie kann ich die optimalen hyperparameter werte finden a: bsp.

Was ist ein Hyperparameter?



Frage 1

RAG fürs Lernen

Antwort: Um den Einfluss von Hyperparametern zu messen, trainieren Sie das Modell mit verschiedenen Hyperparametern und vergleichen Sie die Performance auf den Validierungsdaten.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/Hyperparameter.pdf | Seite: 2]

. solche variablen heißen hyperparameter • unser erstes ziel ist zu verstehen, wie wir den einfluss von hyperparametern messen können und wie wir die optimalen hyperparameter werte finden
hyperparameter am beispiel von nn • wie hängt die performance eines nn modells von ab • wir betrachten als beispiel den palmer penguins datensatz k k k k k modellkomplexität und modellauswahl — ds course book https://ds.coursebook.pages.dev/modellauswahl_knn 2 von 20
24.01.26, 17:00

[Treffer 2 | Quelle: Data/Modellkomplexität und Modellauswahl.pdf | Seite: 2]

. solche variablen heißen hyperparameter • unser erstes ziel ist zu verstehen, wie wir den einfluss von hyperparametern messen können und wie wir die optimalen hyperparameter werte finden
hyperparameter am beispiel von nn • wie hängt die performance eines nn modells von ab • wir betrachten als beispiel den palmer penguins datensatz k k k k k modellkomplexität und modellauswahl — ds course book https://ds.coursebook.pages.dev/modellauswahl_knn 2 von 20
04.04.26, 16:53

[Treffer 3 | Quelle: Data/DS_PruefungsvorbereitungFragenundAntwortenKlein.pdf | Seite: 14]

eigene fragen: 1)was sind hyperparameter a: das sind die parameter die vor dem eigentlichen training festgelegt werden. bei k nn das k. 2)wie kann ich den einfluss von hyperparametern messen a: das modell mit verschiedneen hyperparametern trainieren und die performance auf den validierungsdaten vergleichen

Wie kann ich den Einfluss von Hyperparametern messen?



Frage 2

RAG fürs Lernen

Antwort: Durch die Cross-Validation und Grid Search.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/Hyperparameter.pdf | Seite: 2]

. solche variablen heißen hyperparameter • unser erstes ziel ist zu verstehen, wie wir den einfluss von hyperparametern messen können und wie wir die optimalen hyperparameter werte finden hyperparameter am beispiel von nn • wie hängt die performance eines nn modells von ab • wir betrachten als beispiel den palmer penguins datensatz k k k k k modellkomplexität und modellauswahl — ds course book https://ds.coursebook.pages.dev/modellauswahl_knn 2 von 20 24.01.26, 17:00

[Treffer 2 | Quelle: Data/Modellkomplexität und Modellauswahl.pdf | Seite: 2]

. solche variablen heißen hyperparameter • unser erstes ziel ist zu verstehen, wie wir den einfluss von hyperparametern messen können und wie wir die optimalen hyperparameter werte finden hyperparameter am beispiel von nn • wie hängt die performance eines nn modells von ab • wir betrachten als beispiel den palmer penguins datensatz k k k k k modellkomplexität und modellauswahl — ds course book https://ds.coursebook.pages.dev/modellauswahl_knn 2 von 20 04.04.26, 16:53

[Treffer 3 | Quelle: Data/DS_PruefungsvorbereitungFragenundAntwortenKlein.pdf | Seite: 14]

eigene fragen: 1) was sind hyperparameter a: das sind die parameter die vor dem eigentlichen training festgelegt werden. bei k nn das k. 2) wie kann ich den einfluss von hyperparametern messen a: das modell mit verschiedenen hyperparametern trainieren und die performance auf den validierungsdaten vergleichen. 3) wie kann ich die optimalen hyperparameter werte finden a: bsp.

durch die cross validation, grid search

Wie kann ich die optimalen Hyperparameter-Werte finden?



Frage 3

RAG fürs Lernen

Antwort: Overfitting ist ein Phänomen, bei dem ein Modell sich zu gut an die Trainingsdaten anpasst und wenig über das zu vorherzusagende Problem lernt.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/DS_PruefungsvorbereitungFragenundAntwortenKlein.pdf | Seite: 17]
. 18) ist bei overfitting das k eher zu klein und bei underfitting das k eher zu groß a: ja, bei k nn ist beim overfitting das k eher zu klein (richtig!) und beim underfitting das k eher zu groß. (richtig!) 19) was ist der unterschied zwischen bias und variance a: underfitting > bias overfitting > hohe varianz fehler durch bias: differenz zwischen der durchschnittlichen v orhersage aller modelle und dem wahren zielwert. fehler durch varianz: variabilität der v orhersagen im punkt. seite von 17 39

[Treffer 2 | Quelle: Data/DS_PruefungsvorbereitungFragenundAntwortenKlein.pdf | Seite: 14]
. eine schlechte wahl führt zu underfittung/overfitting. und eine gute wahl verbessert die generalisierung. 8) wie hängt overfitting und underfitting mit der modellkomplexität zusammen a: hohe modell komplexität bedeutet overfitting, trainingsfehler sehr klein, testfehler sehr hoch. niedrige modell komplexität bedeutet underfitting. trainingsfehler sehr hoch und testfehler sehr hoch. das modell ist sehr dumm. seite von 14 39

[Treffer 3 | Quelle: Data/Überwachtes Lernen.pdf | Seite: 10]
• ist perfekt im sinne der erm: der empirische fehler kann nicht kleiner sein • aber er schneidet bei ungesesehenen beispielen sehr schlecht ab (1/2) • dieses phänomen wird als **überanpassung** (overfitting) bezeichnet: das modell passt sich zu gut an die trainingsdaten an, lernt aber wenig über das vorherzusagende problem. erm mit induktivem bias • wir müssen den erm ansatz etwas anpassen, um eine **überanpassung** zu verhindern • d.h. wenn der prädiktor auf den trainingsdaten

Was ist Overfitting?



Frage 4

RAG fürs Lernen

Antwort: Machine Learning wird verwendet, um Informationen aus Daten zu extrahieren.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/Einführung in Maschinelles Lernen.pdf | Seite: 1]

einführung in maschinelles lernen contents • wofür machine learning (ml) • wichtigste konzepte und begriffe des ml • übungen lernziele • verstehen, wofür maschinelles lernen (= machine learning = ml) eingesetzt wird • wichtigste konzepte und begriffe des ml kennenlernen • ein ml problem mathematisch formulieren wofür machine learning (ml) seit einigen jahren ist machine learning (ml) zu einem standardwerkzeug für fast alle aufgaben geworden, bei denen informationen aus daten extrahiert werden müssen • daten: rohinformationen • information: daten mit kontext, verarbeitet, wert. machine learning kommt v.a. zum einsatz bei aufgaben, die wir mit einer expliziten abfolge von regeln nicht gut lösen können. beispiel: objekterkennung in bildern einföhrung in maschinelles lernen — ds course book https://ds-course-book.pages.dev/intro_ml 1 von 15 20.10.25, 21:27

[Treffer 2 | Quelle: Data/Einführung in Maschinelles Lernen.pdf | Seite: 14]

7. der test datensatz wird zum trainieren eines maschinellen lernmodells verwendet. 8. der gradientenabstieg ist ein häufig verwendetes optimierungsverfahren beim deep learning. aufgabe 2 operationalisierung eines ml problems nennen sie einen anwendungsfall für maschinelles lernen, der ihnen im rahmen ihres studiums / ihrer arbeit / oder im täglichen leben bisher begegnet ist. überlegen sie dabei: • welche daten für das training des ml modells genutzt werden könnten, • ob es sich um ein problem des überwachten lernens handelt, und wenn ja, ob es eine regressions oder klassifikationsaufgabe darstellt, • und wie die performanz des modells gemessen werden könnte. aufgabe 3 wahl der fehlermetrik in der vorlesung haben wir den mean squared error (mse) als die übliche loss function für regression kennengelernt. angenommen sie wollen die optimale lineare

Wofür wird Machine Learning verwendet?



Frage 5

RAG fürs Lernen

Antwort: Ein Domain Set ist die mathematische Darstellung von Objekten, die wir klassifizieren wollen.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/Überwachtes Lernen.pdf | Seite: 5]

input des lern algorithmus 1. **urbildmenge** (domain set): mathematische darstellung von objekten, die wir klassifizieren wollen. wird üblicherweise mit bezeichnet. jeder datenpunkt wird als sog. feature vektor dargestellt. 2. bildmenge (zielmenge, label set): klassen oder labels, üblicherweise repräsentiert als oder andere zahlen, v.a. bei mehr als 2 klassen. wird • ich bin auf eine pazifikinsel gezogen. dort scheinen papayas ein wichtiger bestandteil der ernährung zu sein. • wie erkenne ich, welche gut schmecken • welche aspekte sollte ich berücksichtigen basierend auf bisheriger erfahrung mit früchten scheinen farbe und festigkeit besonders relevant. • farbe: von dunkelgrün über orange und rot bis hin zu braun; festigkeit: von steinhart bis hin zu matschig. • ich besorge mir eine (zufällige) auswahl von papayas, probiere sie und notiere, welche gut/schlecht geschmeckt hat. $x_1(), x_2(), \dots, x_n = () 0.1 - 0.6 - 0.3 0$

[Treffer 2 | Quelle: Data/Überwachtes Lernen.pdf | Seite: 19]

. ein teil davon ist bereits numerisch; kategorische attribute müssen über verfahren wie das sog. one hot encoding umgewandelt werden. • anwendungsfall 4 • klassifikationsaufgabe; jedes wort aus dem vokabular ist eine klasse; entsprechend hängt die anzahl von klassen von der gröÙe des vokabulars ab (sehr groß, außer wir reduzieren das geschickt; dazu später im semester mehr) • lyrics aus dem internet herunterladen • für numerische repräsentation gibt es viele möglichkeiten. man kann sog. one hot encoding durchführen (angenommen das vokabular ist alphabetisch sortiert und hat die gröÙe n . dann wird jedes wort repräsentiert als ein vektor der länge n bestehend aus einer 1 an der index position des wortes im vokabular und sonst aus nullen). man kann auch semantische

Was ist ein Domain Set?



Frage 6

RAG fürs Lernen

Antwort: Die IQR Regel stammt von John Tukey.

▼ Gefundene Textstellen anzeigen

[Treffer 1 | Quelle: Data/Deskriptive und Explorative Datenanalyse.pdf | Seite: 18]

. ein viertel der daten enthält. ist z.b. die verteilung annähernd symmetrisch zum median, so sind und ähnlich weit weg vom median entfernt. liegt weiter entfernt vom median als , so weist das auf eine rechtssteile verteilung hin. für metrische merkmale gibt der sog. interquartilsabstand (iqr), definiert als $\$ \$$ aufschluß darüber, wie weit die verteilung auseinander gezogen ist. eine grobe faustregel zur identifikation von ausreißern ist wie folgt: werte, welche außerhalb des intervalls $0 < p < 1 \times p \leq x \leq p - p = x \leq p \times \min q 1 \times 0.25 q 3 \times 0.75 \times \max x 0.25 \times 0.75 \times 0.25 \times 0.75 d q = x 0.75 - x 0.25, [x 0.25 - 1.5 * d q, x 0.75 + 1.5 * d q]$ back to top deskriptive und explorative datenanalyse — ds course book https://ds.coursebook.pages.dev/descriptive_explorative_da 18 von 25 20.10.25, 21:24

[Treffer 2 | Quelle: Data/Data Preprocessing.pdf | Seite: 6]

. • dies hängt allerdings von der zugrundeliegenden statistischen verteilung ab. • wir beschränken uns auf die unabhängige betrachtung einzelner variablen. iqr regel werte oberhalb von und unterhalb von sind gute outlier kandidaten wo kommt die iqr regel her • box whisker plots wurden in 1977 von john tukey eingeführt; er definierte auch diesen grenzwert • hat gut funktioniert und wird weiter benutzt $2.6, 2.8, 3.6 [4, 4, 4, 1.5, 2.4, 2.4, 2.4, 2.4, 3.6] [1, 1, 7, 1.5, 2.1, 2.1, 2.8, 2.8, 3.6] [4, 4, 4, 1.9, 1.9, 1.9, 3.0, 3.0, 3.0] [1, 1, 7, 1.5, 2.1, 2.1, 2.6, 2.6, 3.6] q 3 + 1.5 * iqr q 1 - 1.5 * iqr$ data preprocessing — ds course book https://ds.coursebook.pages.dev/data_preprocessing 6 von 11 20.10.25, 21:25

Wo kommt die IQR Regel her?



Frage 7

6. Auszug einiger Quellen bei der Recherche und verwendete KI-Tools

6.1 KI-Tools:

Perplexity und Github Copilot wurden für Debugging der Seitenanzahl verwendet.

Perplexity wurde für Korrektur von Grammatik und Rechtschreibfehlern verwendet.

6.2 Quellen:

Folien und Notebooks aus dem Kurs Data Science von Prof. Dr. Mihaljevic

Folien und Notebooks aus dem Kurs Besondere Kapitel der Informatik von Elisabeth Steffen

Eigene Notizen

https://docs.ragas.io/en/stable/getstarted/rag_eval/#evaluate

<https://docs.langchain.com/langsmith/evaluate-rag-tutorial>

<https://www.iese.fraunhofer.de/blog/retrieval-augmented-generation-rag/>

<https://docs.langchain.com/oss/python/integrations/vectorstores/chroma>

<https://www.coursera.org/projects/introduction-to-rag#learn>

<https://www.youtube.com/watch?v=x5kDUgx-B8w>

<https://www.youtube.com/watch?v=nOvSQk9kWdE>

Abschlussbemerkung: In den Beispielfragen, sowie Prüfungsnotizen sind zahlreiche Tippfehler, Grammatikfehler, Rechtschreibfehler. Diese sind bewusst behalten worden, da ich meine eigenen Notizen nur selten auf Grammatik etc. korrigiere und die gestellten Fragen somit praxisnaher sind.